

Análise Estatística de dados

Inteligência Artificial



“Intelligence is not just about pattern recognition and function approximation. It’s about modeling the world”.

— Josh Tenenbaum, NeurIPS 2021.

AULA 02 – NOÇÕES DE ÁLGEBRA LINEAR E GEOMETRIA ANALÍTICA

Larissa Driemeier

PROGRAMA DO CURSO

Aula	Data	Conteúdo da Aula
01	18/02	Aula Inaugural
02	25/02	Introdução ao Curso. Noções de Álgebra Linear , Geometria Analítica Parte I
03	11/03	Noções de Álgebra Linear , Geometria Analítica Parte II
04	18/03	Decomposição de valor singular (SVD)
05	25/03	Otimização: derivadas, derivadas parciais (operadores gradiente, Jacobiano, Hessiano e Laplaciano), algoritmos de gradiente, noções de algoritmos genéticos
06	01/04	Variáveis independentes e não independentes. Estatística Descritiva e Indutiva. Definições de medidas de dispersão e tendência central.
07	08/04	Probabilidade e Teorema de Bayes
08	15/04	Modelos de probabilidade discretos/contínuos
09	22/04	Intervalo de confiança e teste de hipóteses
10	29/04	Modelo de Markov. Modelo de Markov oculto.

TOP 10

AVALIAÇÃO

$$M = \sum_i T_i \leq 10$$


média final → M

Soma das notas dos Trabalhos/Testes → T_i


Critério de Aprovação: $M \geq 7,0$

Recuperação: Para alunos cuja média final estiver contida no intervalo $4,0 \leq M < 7,0$ será oferecida uma prova de recuperação, que **substituirá a nota total, e vale, no máximo, 7,0.**


REFERÊNCIAS BIBLIOGRÁFICAS



Deisenroth, M.P.; Faisal, A.A.; Ong, C.S. MATHEMATICS FOR MACHINE LEARNING, Cambridge University Press, 2020.



Bussab, W.; Morettin, P.L.
ESTATÍSTICA BÁSICA, Saraiva,
9ª Edição, 2023



COMUNICADOS IMPORTANTES

- Aluno Web é nosso canal de comunicação. Todo material será depositado ali: notas de aula, listas de exercícios, notas, comunicados, provas, testes ...



The screenshot shows the PECE website homepage. At the top right, there is a red box highlighting the "ÁREA DO ALUNO →" button and the "ATENDIMENTO ONLINE" link below it. A large red arrow points upwards from the bottom left towards this highlighted area. Below the header, there are three main navigation categories: "MBA ▾", "ESPECIALIZAÇÃO ▾", and "OUTROS CURSOS ▾". Under "OUTROS CURSOS", there are three items: "MBA Gestão e Tecnologias Ambientais – MBA", "Especialização Gestão de Projetos de Sistemas Estruturais –", and "Automação de Processos de". At the bottom, there are three icons: "AVALIAÇÃO ONLINE" (document icon), "PORTAL DO ALUNO" (graduation cap icon), and "ALUNO WEB" (student icon). A small text at the bottom center reads: "Nossos eventos estão abertos ao público e refletem a relevância de nossas pesquisas e cursos. Clique no evento desejado e saiba mais."



APRENDIZADO DE MÁQUINAS

O Aprendizado de Máquinas pode resolver:

- Regressão
- Classificação
- Agrupamento (Clustering)
- Redução de Dimensionalidade
- Estimativa de Densidade
- Previsão de Séries Temporais
- Detecção de Anomalias
- Aprendizado por Reforço
- Modelagem Generativa
- Aprendizado Baseado em Grafos
- Otimização & Tomada de Decisão

O Aprendizado de Máquinas pode resolver:

- Regressão** O modelo prevê o preço de um imóvel com base em seu tamanho e localização
- Classificação** O algoritmo identifica se um e-mail é spam ou não com base no seu conteúdo.
- Agrupamento (Clustering)** Os clientes foram agrupados em diferentes perfis de consumo sem necessidade de rótulos prévios.
- Redução de Dimensionalidade** O PCA ajudou a visualizar dados de alta dimensão
- Estimativa de Densidade** A distribuição dos dados foi estimada para entender padrões nos dados e criar modelos gerativos.
- Previsão de Séries Temporais** O modelo prevê a demanda de energia para os próximos dias analisando o histórico de consumo
- Detecção de Anomalias** O sistema identificou uma transação suspeita que pode indicar fraude no cartão de crédito.
- Autonomia em robótica** Um agente de IA aprendeu a jogar xadrez sozinho, recebendo recompensas por boas jogadas
- Modelagem Generativa** Uma rede gerativa criou imagens realistas de rostos que não existem na vida real.
- Aprendizado Baseado em Grafos** O algoritmo analisou conexões em uma rede social para recomendar novas amizades.
- Otimização & Tomada de Decisão** O modelo encontrou a melhor rota de entrega para minimizar custos e tempo de viagem.

ML E ÁLGEBRA LINEAR


(ML, de *Machine Learning*, em inglês)

Nós temos dados. Nós sabemos que no fundo, no fundo, tudo o que o computador entende são números. Para sermos mais exatos, tudo o que o computador entende são 0s e 1s.

A Álgebra Linear é **a matemática dos arrays** — tecnicamente chamados de vetores, matrizes e tensores.

Ela é essencial em ML e Deep Learning (DL). É a base matemática que resolve o problema de representação de dados e cálculos em modelos de ML.

Portanto, o primeiro passo para aprender matemática para ML é aprender álgebra linear.



ESTOU PERDIDO!

Felizmente, não precisamos conhecer álgebra linear em toda sua amplitude e profundidade para melhorar nossa compreensão e aplicação do aprendizado de máquina.


Então não será difícil!!! Você só precisará relembrar alguns conceitos!

Você não tem tempo, e nem deve, mergulhar em livros didáticos de álgebra linear e cursos on-line projetados para estudantes de graduação.

Ela deve ser encarada como mais um conjunto de ferramentas que podemos aproveitar em nossa jornada em direção ao domínio do aprendizado de máquina.

Vamos rever os conceitos básicos rapidamente e cobrir alguns tópicos importantes com maior profundidade.





ESCALARES, VETORES, MATRIZES, TENSORES

Notação básica
Operações e propriedades
Cálculo matricial

$$\mathcal{A} \in \mathbb{R}^{N_1 \times N_2 \times \dots \times N_d}$$


'A' é um tensor de ordem-d

|

$$d = 0$$

Tensor 0D (Escalar)

Shape: ()



$\bar{x} = 24$ (*anos*)

$$\mathcal{A} \in \mathbb{R}^{N_1 \times N_2 \times \dots \times N_d}$$

'A' é um tensor de ordem-d

■

$d = 0$

Tensor 0D (Escalar)

Shape: ()

$d = 1$

Tensor 1D (Vetor)

Shape: (3,)

Lista de atributos de um objeto!



24 anos
feminino
0 filhos
0 casa própria
3 anos com emprego fixo
2200 reais de renda mensal



$$= \begin{bmatrix} 24 \\ 0 \\ 0 \\ 0 \\ 3 \\ 2200 \end{bmatrix}$$

```
x = np.array(42)
print(x)
print('Um escalar tem rank %d' % (x.ndim))
x.ndim, x.shape
```

O número de dimensões (eixos) do array e sua *forma*, respectivamente.

```
→ 42
Um escalar tem rank 0
(0, ())
```

```
x = np.array([24, 0, 0, 0, 3, 2200])
print(x)
print('Um vetor tem rank {:d}'.format(x.ndim))
x.ndim, x.shape
```

```
→ [ 24   0   0   0   3 2200]
Um vetor tem rank 1
(1, (6,))
```

Retorna uma tupla onde cada índice representa o número de elementos correspondentes àquela dimensão.

x.size O número total de elementos

```
→ 6
```

$$\mathcal{A} \in \mathbb{R}^{N_1 \times N_2 \times \dots \times N_d}$$

'A' é um tensor de ordem-d

$d = 0$

Tensor 0D (Escalar)

Shape: ()



$d = 1$

Tensor 1D (Vetor)



Shape: (3,)



$d = 2$

Tensor 2D (Matriz)

Shape: (3,3)



```
[6] 1 x = np.array([[1, 4, 7],  
2                 [2, 5, 8],  
3                 [3, 6, 9]])  
4 print(x)  
5 print('A matriz tem rank {:.d}'.format(x.ndim))  
6 x.ndim,x.shape
```

```
→ [[1 4 7]  
 [2 5 8]  
 [3 6 9]]  
A matriz tem rank 2  
(2, (3, 3))
```

```
[7] 1 x.size
```

```
→ 9
```

$$\mathcal{A} \in \mathbb{R}^{N_1 \times N_2 \times \dots \times N_d}$$

'A' é um tensor de ordem-d

$d = 0$

Tensor 0D (Escalar)
Shape: ()




$d = 1$

Tensor 1D (Vetor)
Shape: (3,)




$d = 2$

Tensor 2D (Matriz)
Shape: (3,3)




$d = 3$

Tensor 3D (Tensor)
Shape: (3,3,3)



240 241 241	207 199 196	234 231 225
240 237 238	183 163 195	223 213 225
239 240 240	183 166 184	219 211 195
238 237 240	176 172 181	176 205 189
240 240 239	184 167 176	168 141 117
239 240 240	182 180 170	160 142 117



```
[8] 1 x = np.array([[1, 4, 7],  
2                 [2, 5, 8],  
3                 [3, 6, 9]],  
4                 [[10, 40, 70],  
5                 [20, 50, 80],  
6                 [30, 60, 90]]])  
7 print(x)  
8 print('O tensor mostrado é de rank {:d}'.format(x.ndim))  
9 x.ndim,x.shape
```

```
[[[ 1  4  7]  
 [ 2  5  8]  
 [ 3  6  9]]  
  
[[10 40 70]  
 [20 50 80]  
 [30 60 90]]]  
O tensor mostrado é de rank 3  
(3, (2, 3, 3))
```

```
[9] 1 x.size
```

```
18
```

```
[8] 1 x = np.array([[[1, 4, 7],  
2                 [2, 5, 8],  
3                 [3, 6, 9]],  
4                 [[10, 40, 70],  
5                 [20, 50, 80],  
6                 [30, 60, 90]]])  
7 print(x)  
8 print('O tensor mostrado é de rank {:d}'.format(x.ndim))  
9 x.ndim,x.shape
```

```
→ [[[ 1  4  7]  
   [ 2  5  8]  
   [ 3  6  9]]]  
  
[[[10 40 70]  
 [20 50 80]  
 [30 60 90]]]  
O tensor mostrado é de rank 3  
(3, (2, 3, 3))
```

```
[9] 1 x.size
```

```
→ 18
```

print(x[:, 0, :]) ???






```
pix = img.load()  
print(img.size) # Para sabermos o número de  
                pixels (largura e altura)  
data=np.array(img)  
print(data.shape)
```

→ (507, 725)
(725, 507, 4)


A imagem no formato PNG possui 4 canais, R (red) B (blue), G (green) e A (alpha). O valor alfa indica a transparência ou opacidade daquele pixel específico. Os valores alfa variam de 0 a 255, onde 0 representa uma cor totalmente transparente e 255 representa uma cor totalmente opaca.



`x, y=0, 0`

```
print(pix[x, y]) # selecionar o valor RGBA de  
um pixel da imagem
```

→ (220, 132, 208, 255)



$$\mathcal{A} \in \mathbb{R}^{N_1 \times N_2 \times \dots \times N_d}$$

'A' é um tensor de ordem-d

$d = 0$

Tensor 0D (Escalar)
Shape: ()



$d = 4$

Tensor 4D (Tensor)
Shape: (3,3,3,3)

$d = 1$

Tensor 1D (Vetor)
Shape: (3,)




$d = 2$

Tensor 2D (Matriz)
Shape: (3,3)




$d = 3$

Tensor 3D (Tensor)
Shape: (3,3,3)



Feliz (0)



Triste (1)

Tensores 4-D são muito úteis para armazenar dados para reconhecimento de imagens em deep learning.

$$\mathcal{A} \in \mathbb{R}^{N_1 \times N_2 \times \dots \times N_d}$$


'A' é um tensor de ordem-d

$d = 0$

Tensor 0D (Escalar)
Shape: ()


$d = 1$

Tensor 1D (Vetor)
Shape: (3,)



$d = 2$

Tensor 2D (Matriz)
Shape: (3,3)



$d = 3$

Tensor 3D (Tensor)
Shape: (3,3,3)



$d = 4$

Tensor 4D (Tensor)
Shape: (3,3,3,3)





$d = 5$

Tensor 5D (Tensor)
Shape: (3,3,3,3,3)






pessoa 0

pessoa 1



Feliz (0)



Triste (1)

$$\mathcal{A} \in \mathbb{R}^{N_1 \times N_2 \times \dots \times N_d}$$

'A' é um tensor de ordem-d

$d = 0$

Tensor 0D (Escalar)
Shape: ()



$d = 1$

Tensor 1D (Vetor)
Shape: (3,)



$d = 2$

Tensor 2D (Matriz)
Shape: (3,3)




$d = 3$

Tensor 3D (Tensor)
Shape: (3,3,3)

$d = 4$
Tensor 4D (Tensor)
Shape: (3,3,3,3)

$d = 5$
Tensor 5D (Tensor)
Shape: (3,3,3,3,3)




$d = 6$

Tensor 6D (Tensor)
Shape: (3,3,3,3,3,3)



Masculino (1)





1D



2D




3D



4D




5D



6D

MNIST é um banco de dados de 60.000 imagens de dígitos manuscritos, em escala de cinza (28x28 pixels). Ele é armazenado em um tensor 3-D, $60000 \times 28 \times 28$



CIFAR-10 é um banco de dados de imagens coloridas de objetos. Contém 60.000 imagens coloridas (32x32 pixels) divididas em 10 categorias: avião, automóvel, pássaro, gato, cervo, cachorro, sapo, cavalo, navio, caminhão. Ele é armazenado em um tensor 3-D,
 $60000 \times 32 \times 32 \times 3$

Vamos considerar um exemplo de um vídeo de 5 minutos com resolução HD 1080. A dimensão da estrutura de dados pode ser calculada da seguinte forma:

- O tamanho do quadro (frame) é de **1080 x 1920 pixels**.
- A duração do vídeo é de **5 minutos**, ou seja, $5 \times 60 = 300$ segundos.
- Se o vídeo for amostrado a **10 quadros por segundo**, o número total de quadros será $300 \times 10 = 3000$ quadros.
- Suponha que o vídeo tenha uma **profundidade de cor de 3 canais (RGB)**



...



Isso significa que temos um total de **3000 quadros**, cada um com uma matriz de **1080 x 1920 pixels**, e cada pixel é representado por **3 valores** (um para cada canal de cor: vermelho, verde e azul).

Portanto, um único vídeo pode ser representado como um tensor 4D


$$(3000, 1080, 1920, 3)$$

Se quisermos armazenar múltiplos vídeos, como **10 clipes de vídeo** com resolução **HD 1080**, precisaríamos de um **tensor 5D**:


(10, 3000, 1080, 1920, 3)

Isso significa que o tensor contém **10 vídeos**, cada um sendo um tensor **4D (3000, 1080, 1920, 3)**.

- **10** representa o número de vídeos,
- **3000** é o número de quadros por vídeo,
- **1080 e 1920** são a altura e largura de cada quadro,
- **3** representa os canais de cor (RGB).



REPRESENTAÇÃO ESPACIAL



DESAFIO

1. Qual o nível de cor verde do pixel (350,250) do elefante?
2. Como tirar a componente de cor vermelha de todos os pixels do elefante?
3. Como deixar o elefante transparente?
4. Rode o seguinte código e descreva o que a função `Image.thumbnail` fez com a imagem do elefante:

```
img.thumbnail((64, 64), Image.LANCZOS)  
  
# resizes image in-place  
  
imgplot = plt.imshow(img);  
  
data=np.array(img)  
  
data.shape
```





VETORES

VETORES

O vetor $x \in \mathbb{R}^n$ é dito vetor coluna de dimensão n se possuir n linhas e 1 coluna

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix}$$

x_i é o i-ésimo elemento do vetor x


Para expressar o vetor linha,

$$x^T = [x_1 \quad x_2 \quad \dots \quad x_n]$$

calcula-se o transposto de x , isto é, um vetor de 1 linha e n colunas.

$$\begin{bmatrix} 1 \\ 2 \end{bmatrix}^T = [1 \ 2]$$

BASE DE UM CONJUNTO DE VETORES



$$r = r_1 \hat{e}_1 + r_2 \hat{e}_2$$

Base de vetores
 (bidimensional) de nosso
 sistema de coordenadas.

“VETOR DE CARACTERÍSTICAS”

Para nosso universo de IA, vetor é uma lista de atributos de um objeto!



450 m²
5 quartos
6 banheiro
850000 reais



$$\begin{bmatrix} 450 \\ 5 \\ 6 \\ 850 \end{bmatrix}$$

OPERAÇÕES BÁSICAS COM VETORES




$$\frac{r}{2} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$



$$r = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \quad \begin{array}{l} \text{\#quartos} \\ \text{\#banheiros} \end{array}$$



$$2r = \begin{bmatrix} 4 \\ 4 \end{bmatrix}$$





$$r = r_1 \hat{e}_1 + r_2 \hat{e}_2 = 2\hat{e}_1 + 2\hat{e}_2$$

$$4 \times \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 1 \times 4 \\ 2 \times 4 \\ 3 \times 4 \end{bmatrix} = \begin{bmatrix} 4 \\ 8 \\ 12 \end{bmatrix}$$




$$\mathbf{r}' = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 5 \\ 6 \end{bmatrix}$$






$$s + r = r + s = \begin{bmatrix} -1 \\ 1 \end{bmatrix} + \begin{bmatrix} 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \end{bmatrix}$$



$$s + (-s) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$



$$r + s + t = \begin{bmatrix} -1 \\ 1 \end{bmatrix} + \begin{bmatrix} 2 \\ 3 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 5 \end{bmatrix}$$

$$(r + s) + t = r + (s + t)$$

$$\left(\begin{bmatrix} 2 \\ 3 \end{bmatrix} + \begin{bmatrix} -1 \\ 1 \end{bmatrix} \right) + \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \end{bmatrix} + \left(\begin{bmatrix} -1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} \right)$$

PRODUTO INTERNO ENTRE VETORES

O produto escalar é a principal ferramenta para calcular projeções de vetores, decomposições de vetores e determinar ortogonalidade.

$x, y \in \mathbb{R}^n$ calcula-se $x^T y \in \mathbb{R}$

$$v = x^T y = [x_1 \quad x_2 \quad \dots \quad x_n] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = x_1 y_1 + x_2 y_2 + \dots + x_n y_n = \sum_{i=1}^n x_i y_i$$


$$x^T y = y^T x$$

POR EXEMPLO...

Ache o produto interno entre os seguintes vetores,

$$\mathbf{r} = \begin{bmatrix} -5 \\ 3 \\ 2 \\ 8 \end{bmatrix} \quad \mathbf{s} = \begin{bmatrix} 1 \\ 2 \\ -1 \\ 0 \end{bmatrix}$$

ERRO MÉDIO QUADRÁTICO E O PRODUTO INTERNO



$$\hat{y} = x\beta = \begin{bmatrix} \beta_0 + \beta_1 x_1 \\ \beta_0 + \beta_1 x_2 \\ \vdots \\ \beta_0 + \beta_1 x_n \end{bmatrix}$$


Vetor $n \times 1$ que contém as previsões pontuais

$$e(\beta_0, \beta_1) = y - x\beta = y - \hat{y}$$

$$MSE(\beta) = \frac{1}{n} \sum_{i=1}^n e_i^2(\beta)$$

$$MSE(\beta) = \frac{1}{n} [e_1 e_2 \dots e_n] \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix}$$

CARACTERÍSTICAS DO PRODUTO INTERNO




$$r = r_1 \hat{e}_1 + r_2 \hat{e}_2 = 2\hat{e}_1 + 3\hat{e}_2$$

$$r \cdot r = [r_1 \quad r_2] \begin{bmatrix} r_1 \\ r_2 \end{bmatrix}$$

$$r \cdot r = r_1^2 + r_2^2 = \left(\sqrt{r_1^2 + r_2^2} \right)^2 = \|r\|^2$$

Se queremos saber a dimensão de um vetor,
basta tirar a raiz do seu produto interno.

EXTRAPOLANDO...




Podemos extender para qualquer dimensão: o tamanho de um vetor é a raiz quadrada da soma dos quadrados de seus componentes.
 Por exemplo,

$$s = \begin{bmatrix} 1 \\ 3 \\ 5 \\ 1 \end{bmatrix}$$

$$\|s\| = \sqrt{36} = 6$$

PRODUTO INTERNO E O ÂNGULO ENTRE VETORES



Relação entre produto interno e ângulo,

$$\mathbf{r} \cdot \mathbf{s} = \mathbf{r}^T \mathbf{s} = \|\mathbf{r}\| \|\mathbf{s}\| \cos \theta$$

$$(\mathbf{r} \cdot \mathbf{s} = \mathbf{r}^T \mathbf{s} = \mathbf{s}^T \mathbf{r})$$

$$\mathbf{r} = \begin{bmatrix} r_1 \\ r_2 \end{bmatrix}, \mathbf{s} = \begin{bmatrix} s_1 \\ s_2 \end{bmatrix}$$

$$\mathbf{r}^T \mathbf{s} = [r_1 \quad r_2] \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} = r_1 s_1 + r_2 s_2$$

$$\mathbf{r} \cdot \mathbf{r} = \mathbf{r}^T \mathbf{r} = [r_1 \quad r_2] \begin{bmatrix} r_1 \\ r_2 \end{bmatrix} = r_1 r_1 + r_2 r_2 = r_1^2 + r_2^2 = \|\mathbf{r}\|^2$$

VETORES ORTOGONIAIS E ORTONORMAIS

Dois vetores são ortogonais, $\cos \theta = 90^\circ$, se seu produto interno é nulo,

$$\frac{\mathbf{r} \cdot \mathbf{s}}{\|\mathbf{r}\| \|\mathbf{s}\|} = \cos \theta \rightarrow \mathbf{r} \cdot \mathbf{s} = 0$$

Um vetor é normalizado se sua dimensão é unitária, ié,

$$\|\mathbf{r}\| = 1$$

Podemos normalizar um vetor...

$$\mathbf{r}' = \frac{\mathbf{r}}{\|\mathbf{r}\|}, \mathbf{s}' = \frac{\mathbf{s}}{\|\mathbf{s}\|}, \mathbf{r}' \cdot \mathbf{s}' = 0$$



É impossível ter mais de n vetores independentes mutuamente ortogonais em \mathbb{R}^n

Dois vetores \mathbf{r}, \mathbf{s} são ditos ortogonais quando separados por 90° .

Vetor unitário ou versor é aquele cuja norma é 1 .

Quando a norma dos vetores ortogonais é unitária, eles são chamados ortonormais $(\mathbf{r}', \mathbf{s}')$.

PROJEÇÃO ESCALAR E VETORIAL



Projeção escalar é o tamanho do vetor laranja.


$$\frac{\mathbf{r} \cdot \mathbf{s}}{\|\mathbf{r}\|} = \|\mathbf{s}\| \cos \theta$$

Projeção vetorial é um escalonamento do vetor \mathbf{r}

$$\frac{\mathbf{r} \cdot \mathbf{s}}{\|\mathbf{r}\|} \frac{\mathbf{r}}{\|\mathbf{r}\|} = \frac{\mathbf{r} \cdot \mathbf{s}}{\mathbf{r} \cdot \mathbf{r}} \mathbf{r}$$

A definição de projeção escalar é o comprimento da projeção vetorial.

RESUMINDO...




EXEMPLO

A projeção pode ser feita em qualquer dimensão. Por exemplo,

$$\mathbf{r} = \begin{bmatrix} 3 \\ -4 \\ 0 \end{bmatrix} \quad \mathbf{s} = \begin{bmatrix} 10 \\ 5 \\ -6 \end{bmatrix}$$

Qual a projeção escalar e vetorial de \mathbf{s} em \mathbf{r} ?




REDUÇÃO DE DIMENSIONALIDADE

As projeções são uma classe importante de transformações lineares.

No aprendizado de máquina, geralmente lidamos com dados de alta dimensão, que são geralmente difíceis de analisar ou visualizar.

No entanto, dados de alta dimensão muitas vezes possuem a propriedade de que apenas algumas dimensões contêm mais informações, e a maioria das outras dimensões não são essenciais para descrever as principais propriedades dos dados.





EMBEDDING


Todo modelo é, por baixo dos panos, um modelo matemático. E nós só fazemos matemática com números. Isso se aplica aos modelos estatísticos clássicos.

Se aplica aos modelos de Visão Computacional, que transformam pixels em números.

Se aplica também a modelos de linguagem transformando texto em números com Token e Embedding.







 - (0.5, 8)

 - (1, 8)

 - (1, 7)

 - (6, 7)

 - (7, 7)

 - (1, 1)

 - (1, 2)

 - (1, 2)

 - (5.9, 1)

Se a sua resposta foi
“depende”, parabéns!
Você acertou. E vai
depender justamente
do contexto. E para
entender todo o
contexto, é onde
o Mecanismo de
Atenção faz toda a
diferença.

Mas, isso é assunto
para nosso curso...

PRODUTO EXTERNO ENTRE VETORES

$x \in \mathbb{R}^m, y \in \mathbb{R}^n$ calcula-se $xy^T \in \mathbb{R}^{m \times n}$

$$A = xy^T = \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_m \end{bmatrix} [y_1 \quad y_2 \quad \dots \quad y_n] = \boxed{\begin{bmatrix} x_1y_1 & x_1y_2 & \dots & x_1y_n \\ x_2y_1 & x_2y_2 & \dots & x_2y_n \\ \dots & \dots & \dots & \dots \\ x_my_1 & x_my_2 & \dots & x_my_n \end{bmatrix}}$$

Matriz



MATRIZES

MATRIZ DE CARACTERÍSTICAS

Para nosso universo de IA, matriz é constituída de várias listas de atributos de diferentes objetos!



450 m²
5 quartos
6 banheiro
850000 reais



[450 5 6 850]

A linha contém valores para todas as variáveis para aquela observação específica, representando uma única observação ou ponto de dados.

MATRIZ DE CARACTERÍSTICAS

Para nosso universo de IA, matriz é constituída de várias listas de atributos de diferentes objetos!



200 m²
3 quartos
4 banheiro
450000 reais


$$\begin{bmatrix} 450 & 5 & 6 & 850 \\ 200 & 3 & 4 & 450 \end{bmatrix}$$

Cada coluna contém valores de dados para uma variável ou característica. Pense nas colunas como representando os atributos ou características do conjunto de dados.

MATRIZES

Seja $A \in \mathbb{R}^{m \times n}$ uma matriz com **m linhas e n colunas** ($m \times n$ é a dimensão da matriz)

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

Cada linha é uma observação/dado/amostra

Cada coluna é uma característica/variável

a_{ij} é o elemento da i -ésima linha da j -ésima coluna de A

a_{ij} é **j -ésima característica** da **i -ésima observação**

Neste exemplo cada uma das m observações tem n características.

A i -ésima coluna, $\mathbf{a}_i = a_{:,i}$

$$A = \begin{bmatrix} | & | & & | \\ a_1 & a_2 & \cdots & a_n \\ | & | & & | \end{bmatrix}$$

A j -ésima linha, $\mathbf{a}'_j = a_{j,:}$

$$A = \begin{bmatrix} - & a'_1 & - \\ - & a'_2 & - \\ - & \vdots & - \\ - & a'_m & - \end{bmatrix}$$



MATRIZES ESPECIAIS

Simétricas, ortogonais,
identidade...

MATRIZ IDENTIDADE, $I \in \mathbb{R}^{n \times n}$

É uma matriz quadrada de dimensões $n \times n$, definida como valor 1 nos termos da diagonal principal e 0 nos demais,

$$I_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

Para $A \in \mathbb{R}^{m \times n}$,

$$AI = A = IA$$

$$I =$$

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

MATRIZ DIAGONAL

Uma matriz diagonal é uma matriz quadrada em que todos os termos fora da diagonal são 0. Nos demais,

$$I_{ij} = \begin{cases} d_i & i = j \\ 0 & i \neq j \end{cases}$$

1	0	0
0	8	0
0	0	4

Denomina-se, normalmente, $D = \text{diag}(d_1, d_2, \dots, d_n)$. A matriz identidade é um caso particular da matriz diagonal $I = \text{diag}(1, 1, \dots, 1)$

MATRIZES ORTOGONAIS

Uma matriz quadrada $U \in \mathbb{R}^{n \times n}$ é **ortogonal** se todas as suas colunas forem ortogonais entre si e normalizadas (as colunas são chamadas de ortonormais). Segue-se imediatamente da definição de ortogonalidade e normalidade que,

$$U^T U = I = UU^T$$

Exemplo clássico é a matriz de rotação...

$$\begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$$

OPA, E O QUE É VETOR ORTONORMAL???

$$U = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} = \begin{pmatrix} | & | \\ u_1 & u_2 \\ | & | \end{pmatrix}$$

São normalizados?

$$u_1 = \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix} \quad \|u_1\|^2 = u_1 \cdot u_1 = u_{11}^2 + u_{12}^2 = \cos^2 \theta + \sin^2 \theta = 1$$

$$u_2 = \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix} \quad \|u_2\|^2 = u_2 \cdot u_2 = u_{21}^2 + u_{22}^2 = (-\sin \theta)^2 + \cos^2 \theta = 1$$

OPA, E O QUE É VETOR ORTONORMAL???

$$U = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} = \begin{pmatrix} | & | \\ u_1 & u_2 \\ | & | \end{pmatrix}$$

São ortogonais?

$$u_1 = \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix}$$

$$u_2 = \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix}$$

$$u_1 \cdot u_2 = u_{11}u_{21} + u_{12}u_{22}$$

$$u_1 \cdot u_2 = \cos \theta (-\sin \theta) + \sin \theta \cos \theta = 0$$



OPERAÇÕES

Adição de matrizes
Multiplicação por um escalar
Multiplicação entre:
matriz e vetor
entre matrizes

ADIÇÃO

$$\begin{bmatrix} 2 & 3 & 4 \\ 5 & 2 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 4 & 2 \\ 4 & 3 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 7 & 6 \\ 9 & 5 & 1 \end{bmatrix}$$

Adição elemento a elemento, somente matrizes com as mesmas dimensões podem ser adicionadas

MULTIPLICAÇÃO POR ESCALAR

$$\begin{bmatrix} 2 & 3 & 4 \\ 5 & 2 & 0 \end{bmatrix} \times 2 = \begin{bmatrix} 4 & 6 & 8 \\ 10 & 4 & 0 \end{bmatrix}$$

The diagram illustrates scalar multiplication. A red bracket above the first row of the matrix [2 3 4] has a red 'x' symbol above it, indicating multiplication by 2. A red bracket above the scalar 2 also has a red 'x' symbol above it. A red bracket above the second row of the matrix [5 2 0] has an '=' symbol above it, indicating the result of the multiplication.

Multiplicação de cada elemento por um escalar

PRODUTO ENTRE MATRIZ E VETOR

$$A \in \mathbb{R}^{m \times n} \text{ e } v, x \in \mathbb{R}^{n \times 1}$$

$$Ax = v$$

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \times \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1x_1 + 2x_2 \\ 3x_1 + 4x_2 \end{bmatrix}$$

$$v = Ax = \begin{bmatrix} - & a'_1 & - \\ - & a'_2 & - \\ - & \vdots & - \\ - & a'_m & - \end{bmatrix} x = \begin{bmatrix} a'_1 x \\ a'_2 x \\ \vdots \\ a'_m x \end{bmatrix}$$

a i -ésima entrada de v é igual ao produto da i -ésima linha de A por x , $v_i = a'_i x$

MULTIPLICAÇÃO ENTRE MATRIZ E VETOR

$$\begin{bmatrix} 1 \\ 3 \end{bmatrix} \begin{bmatrix} 2 \\ 4 \end{bmatrix} \times \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1x_1 \\ 3x_1 \end{bmatrix} + \begin{bmatrix} 2x_2 \\ 4x_2 \end{bmatrix}$$

$$v = Ax = \begin{bmatrix} | & | \\ a_1 & a_2 \\ | & | \end{bmatrix} \cdots \begin{bmatrix} | \\ a_n \\ | \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

Características/variáveis


$$\begin{bmatrix} | \\ a_n \\ | \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} | \\ a_1 \\ | \end{bmatrix} x_1 + \begin{bmatrix} | \\ a_2 \\ | \end{bmatrix} x_2 + \cdots + \begin{bmatrix} | \\ a_n \\ | \end{bmatrix} x_n$$

v é uma combinação linear das características, onde os coeficientes da combinação linear são dados pelas entradas de x .

$$\begin{bmatrix} 2 & 3 & 4 \\ 5 & 2 & 0 \end{bmatrix} \times \begin{bmatrix} 2 \\ 1 \\ 4 \end{bmatrix} = 2 \begin{bmatrix} 2 \\ 5 \end{bmatrix} + 1 \begin{bmatrix} 3 \\ 2 \end{bmatrix} + 4 \begin{bmatrix} 4 \\ 0 \end{bmatrix}$$

$$= \begin{bmatrix} 23 \\ 12 \end{bmatrix}$$

PORQUE ESSE PRODUTO É IMPORTANTE...



$$\begin{bmatrix} w_{11} & w_{21} \\ w_{12} & w_{22} \\ w_{13} & w_{23} \end{bmatrix} \cdot \begin{bmatrix} i_1 \\ i_2 \end{bmatrix} = \begin{bmatrix} (w_{11} \times i_1) + (w_{21} \times i_2) \\ (w_{12} \times i_1) + (w_{22} \times i_2) \\ (w_{13} \times i_1) + (w_{23} \times i_2) \end{bmatrix}$$

MULTIPLICAÇÃO ENTRE MATRIZES

$$\begin{array}{ccc} \text{blue} & \times & \text{yellow} \\ \text{yellow} & \times & \text{blue} \end{array} = \begin{array}{c} \text{green} \\ \text{green} \end{array}$$

$$A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times p} \rightarrow C \in \mathbb{R}^{m \times p}$$

$$C = AB = \begin{bmatrix} - & a'_1 & - \\ - & a'_2 & - \\ - & \vdots & - \\ - & a'_m & - \end{bmatrix} \begin{bmatrix} | & & | & & | \\ b_1 & b_2 & \dots & b_p \\ | & & | & & | \end{bmatrix} = \begin{bmatrix} a'_1 b_1 & a'_1 b_2 & \cdots & a'_1 b_p \\ a'_2 b_1 & a'_2 b_2 & \cdots & a'_2 b_p \\ \vdots & \vdots & \ddots & \vdots \\ a'_m b_1 & a'_m b_2 & \cdots & a'_m b_p \end{bmatrix}$$

$m \times n$ $n \times p$ $m \times p$

$$\begin{bmatrix} 2 & 3 & 4 \\ 5 & 2 & 0 \end{bmatrix}_{2 \times 3} \times \begin{bmatrix} 2 & 1 \\ 2 & 3 \\ 0 & 1 \end{bmatrix}_{3 \times 2} = \begin{bmatrix} 10 & 15 \\ 14 & 11 \end{bmatrix}_{2 \times 2}$$

Resultando em uma matriz com dimensões iguais ao número de linhas da primeira matriz e ao número de colunas da segunda matriz

EXEMPLO

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \\ 10 & 11 & 12 \end{bmatrix} \quad B = \begin{bmatrix} 2 & 7 \\ 1 & 2 \\ 3 & 6 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \\ 10 & 11 & 12 \end{bmatrix} \begin{bmatrix} 2 & 7 \\ 1 & 2 \\ 3 & 6 \end{bmatrix} = ?$$

VÁRIAS VISÕES DE $C = AB$

$$C = AB = A \begin{bmatrix} | & | & & | \\ b_1 & b_2 & \cdots & b_p \\ | & | & & | \end{bmatrix} = \begin{bmatrix} | & & | \\ A\mathbf{b}_1 & A\mathbf{b}_2 & \cdots & A\mathbf{b}_p \\ | & & | \end{bmatrix}$$

$c_i = A\mathbf{b}_i$

Colunas de C vistas como produtos entre a matriz A e os vetores formados pelas colunas de B .

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \times \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} = \begin{bmatrix} 1 \times 5 + 2 \times 7 \\ 3 \times 5 + 4 \times 7 \end{bmatrix} = \begin{bmatrix} 1 \times 6 + 2 \times 8 \\ 3 \times 6 + 4 \times 8 \end{bmatrix} = \begin{bmatrix} 5 + 14 \\ 15 + 28 \end{bmatrix} = \begin{bmatrix} 6 + 16 \\ 18 + 32 \end{bmatrix} = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}$$

Cada coluna de C é uma combinação linear diferente das características, onde os coeficientes de cada combinação linear são dados pelas colunas de B .

TREINE O RACIOCÍNIO...

Suponha que você tenha um conjunto de dados com as notas de 4 alunos em 3 áreas do conhecimento (Matemática, Ciências e Humanidades). Cada universidade tem uma matriz de pesos diferente para calcular a nota final de ingresso. A escola deseja saber em quais universidades seus alunos têm mais chances de sucesso.

- a) Determine em qual universidade cada aluno tem a maior nota final.
- b) Interprete os resultados para identificar onde os alunos têm mais chances de sucesso.

Aluno	Matemática	Ciências	Humanidades
01	8,0	7,5	9,0
02	6,0	8,0	7,0
03	9,0	9,5	8,5
04	7,5	6,5	8,0

Universidade	Peso Matemática	Peso Ciências	Peso Humanidades
A	0,5	0,3	0,2
B	0,3	0,4	0,3
C	0,2	0,5	0,3

VÁRIAS VISÕES DE $C = AB$

$$C = AB = \begin{bmatrix} | & & | \\ a_1 & a_2 & \cdots & a_n \\ | & & | \end{bmatrix} \begin{bmatrix} - & b'_1 & - \\ - & b'_2 & - \\ \vdots & - & - \\ - & b'_n & - \end{bmatrix} = \sum_{i=1}^n a_i b'_i$$

Multiplicação de matrizes
vista como **produto**
externo

$$\begin{bmatrix} 1 & 2 \\ -3 & 4 \end{bmatrix} \times \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} = \begin{bmatrix} 1 \times 5 \\ 3 \times 5 \end{bmatrix} \begin{bmatrix} 1 \times 6 \\ 3 \times 6 \end{bmatrix} = \begin{bmatrix} 5 \\ 15 \\ 6 \\ 18 \end{bmatrix}$$

VÁRIAS VISÕES DE $C = AB$

$$C = AB = \begin{bmatrix} | & | \\ a_1 & a_2 \\ | & | \end{bmatrix} \cdots \begin{bmatrix} | & | \\ a_n & | \end{bmatrix} \begin{bmatrix} - & b'_1 & - \\ - & b'_2 & - \\ \vdots & \vdots & \vdots \\ - & b'_n & - \end{bmatrix} = \sum_{i=1}^n a_i b'_i$$

Multiplicação de matrizes
vista como **produto**
externo

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \times \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} = \begin{bmatrix} 1 \times 5 + 2 \times 7 & 1 \times 6 + 2 \times 8 \\ 3 \times 5 + 4 \times 7 & 3 \times 6 + 4 \times 8 \end{bmatrix} = \begin{bmatrix} 5 + 14 & 6 + 16 \\ 15 + 28 & 18 + 32 \end{bmatrix} = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}$$

$$\mathbf{C} = \mathbf{AB} = \begin{bmatrix} - & \mathbf{a}'_1 & - \\ - & \mathbf{a}'_2 & - \\ - & \vdots & - \\ - & \mathbf{a}'_m & - \end{bmatrix} \mathbf{B} = \begin{bmatrix} - & \mathbf{a}'_1 \mathbf{B} & - \\ - & \mathbf{a}'_2 \mathbf{B} & - \\ - & \vdots & - \\ - & \mathbf{a}'_m \mathbf{B} & - \end{bmatrix}, \quad \mathbf{c}'_i = \mathbf{a}'_i \mathbf{B}$$

Linhas de \mathbf{C} vistas como produtos entre os vetores formados pelas linhas de \mathbf{A} e a matriz \mathbf{B} .

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \times \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} = \begin{bmatrix} 1 \times 5 + 2 \times 7 & 1 \times 6 + 2 \times 8 \\ 3 \times 5 + 4 \times 7 & 3 \times 6 + 4 \times 8 \end{bmatrix} = \begin{bmatrix} 5 + 14 & 6 + 16 \\ 15 + 28 & 18 + 32 \end{bmatrix} = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}$$

MATRIZ TRANSPOSTA

A transposição de uma matriz resulta na troca das linhas pelas colunas. Dada uma matriz $A \in \mathbb{R}^{m \times n}$, sua transposição, escrita $A^T \in \mathbb{R}^{n \times m}$, é a matriz $n \times m$ cujas entradas são dadas por

$$(A^T)_{ij} = a_{ji}$$

$$m \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}^T = n \begin{bmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{bmatrix}$$

Quando $A^T = A$ a matriz é dita **simétrica** (somente matrizes quadradas, $m = n$, podem ser simétricas).

MATRIZ SIMÉTRICA E ANTI-SIMÉTRICA, $A \in \mathbb{R}^{m \times m}$

Simétrica

$$A = A^T$$

Anti-simétrica

$$A = -A^T$$

Toda matriz pode ser escrita como uma soma de uma parcela simétrica e outra anti-simétrica,

$$A = \frac{1}{2}(A + A^T) + \frac{1}{2}(A - A^T)$$

SÓ PARA CONSTAR...

$$A = \begin{bmatrix} 3 & 3 & -1 \\ -2 & -2 & 1 \\ -4 & -5 & 2 \end{bmatrix} \quad A^T = \begin{bmatrix} 3 & -2 & -4 \\ 3 & -2 & -5 \\ -1 & 1 & 2 \end{bmatrix}$$

$$D = A + A^T = \begin{bmatrix} 3+3 & 3-2 & -1-4 \\ -2+3 & -2-2 & 1-5 \\ -4-1 & -5+1 & 2+2 \end{bmatrix} = \begin{bmatrix} 6 & 1 & -5 \\ 1 & -4 & -4 \\ -5 & -4 & 4 \end{bmatrix} \quad \text{Simétrica... } (D = D^T)$$

$$S = A - A^T = \begin{bmatrix} 3-3 & 3+2 & -1+4 \\ -2-3 & -2+2 & 1+5 \\ -4+1 & -5-1 & 2-2 \end{bmatrix} = \begin{bmatrix} 0 & 5 & 3 \\ -5 & 0 & 6 \\ -3 & -6 & 0 \end{bmatrix} \quad \text{Anti-Simétrica... } (S = -S^T)$$

$$\frac{1}{2}(A + A^T) = \frac{1}{2} \begin{bmatrix} 6 & 1 & -5 \\ 1 & -4 & -4 \\ -5 & -4 & 4 \end{bmatrix}$$

$$\frac{1}{2}(A - A^T) = \frac{1}{2} \begin{bmatrix} 0 & 5 & 3 \\ -5 & 0 & 6 \\ -3 & -6 & 0 \end{bmatrix}$$

$$\frac{1}{2} \begin{bmatrix} 6 & 1 & -5 \\ 1 & -4 & -4 \\ -5 & -4 & 4 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 0 & 5 & 3 \\ -5 & 0 & 6 \\ -3 & -6 & 0 \end{bmatrix} = \begin{bmatrix} \frac{6}{2} + 0 & \frac{1}{2} + \frac{5}{2} & \frac{-5}{2} + \frac{3}{2} \\ \frac{1}{2} + \frac{-5}{2} & \frac{-4}{2} & \frac{-4}{2} + \frac{6}{2} \\ \frac{-5}{2} + \frac{-3}{2} & \frac{-4}{2} + \frac{-6}{2} & \frac{4}{2} \end{bmatrix} = \boxed{\begin{bmatrix} 3 & 3 & -1 \\ -2 & -2 & 1 \\ -4 & -5 & 2 \end{bmatrix}}$$

A

TRAÇO DE UMA MATRIZ

O traço de uma matriz é a soma de sua diagonal principal,

$$\text{tr } A = \sum_{i=1}^n a_{ii}$$


$$A \in \mathbb{R}^{n \times n}, \quad \text{tr } A = \text{tr } A^T$$

$$A, B \in \mathbb{R}^{n \times n}, \quad \text{tr}(A + B) = \text{tr } A + \text{tr } B$$

$$A \in \mathbb{R}^{n \times n}, k \in \mathbb{R} \quad \text{tr}(kA) = k \text{ tr } A$$

$$A, B \text{ tal que } AB \text{ é quadrada } \text{tr}(AB) = \text{tr}(BA)$$

$$A, B, C \text{ tal que } ABC \text{ é quadrada } \text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB)$$



Traço

$$0 + 6 + 1 = 7$$

PROPRIEDADES DA MULTIPLICAÇÃO DE MATRIZES

Multiplicação de matrizes é distributiva e associativa,

$$(AB)C = A(BC)$$
$$A(B + C) = AB + AC$$

mas somente em casos especiais é comutativa. Em geral,

$$AB \neq BA$$

IMPORTANTE... $ABC \neq CAB \neq BCA$

$$\mathbf{A} = \begin{bmatrix} 4 & 12 \\ 7 & 6 \end{bmatrix}$$

$$\mathbf{B} = \begin{bmatrix} 1 & -3 \\ 4 & 3 \end{bmatrix}$$

$$\mathbf{C} = \begin{bmatrix} 6 & 6 \\ 2 & 5 \end{bmatrix}$$

$$\mathbf{ABC} = \begin{bmatrix} 360 & 432 \\ 180 & 171 \end{bmatrix}$$

$$\mathbf{CAB} = \begin{bmatrix} 498 & 126 \\ 259 & 33 \end{bmatrix}$$

$$\mathbf{BCA} = \begin{bmatrix} -63 & -54 \\ 393 & 594 \end{bmatrix}$$

Lembram-se da
propriedade do traço?

$$\text{Tr}(\mathbf{ABC}) = \text{Tr}(\mathbf{CAB}) = \text{Tr}(\mathbf{BCA}) = 531$$

MATRIZ IDENTIDADE E MATRIZ INVERSA

$$AA^{-1} = I$$

A^{-1} é a matriz inversa de A

$$\begin{array}{c}
 \text{A} \quad \text{---} \\
 \text{---} \quad \text{---} \\
 \left[\begin{matrix} -3 & 1 \\ 5 & 0 \end{matrix} \right] \left[\begin{matrix} 0 & 1 \\ \frac{1}{5} & \frac{3}{5} \\ 1 & -\frac{1}{5} \end{matrix} \right] = \left[\begin{matrix} 1 & 0 \\ 0 & 1 \end{matrix} \right]
 \end{array}$$






OPERAÇÕES BÁSICAS


LEMBRAM-SE DA MATRIZ I ?

Primeiro, vamos
pensar em uma
matriz que não muda
nada.




$$\begin{bmatrix}
 1 & 0 & 0 & 0 \\
 0 & 1 & 0 & 0 \\
 0 & 0 & 1 & 0 \\
 0 & 0 & 0 & 1
 \end{bmatrix}
 \begin{bmatrix}
 1 \\
 2 \\
 3 \\
 4
 \end{bmatrix}
 =
 \begin{bmatrix}
 1 \times 1 \\
 1 \times 2 \\
 1 \times 3 \\
 1 \times 4
 \end{bmatrix}
 =
 \begin{bmatrix}
 1 \\
 2 \\
 3 \\
 4
 \end{bmatrix}$$

SE $x = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, QUAL RESULTADO Ax ?





$$A = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$$



$$A = \begin{pmatrix} 2 & -1 \\ 1 & 3 \end{pmatrix}$$

SE $x = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, QUAL RESULTADO Ax ?



$$A = \begin{pmatrix} \cos 45^\circ & -\sin 45^\circ \\ \sin 45^\circ & \cos 45^\circ \end{pmatrix} = \begin{pmatrix} \sqrt{2}/2 & -\sqrt{2}/2 \\ \sqrt{2}/2 & \sqrt{2}/2 \end{pmatrix}$$

$$A = \begin{pmatrix} \cos 90^\circ & -\sin 90^\circ \\ \sin 90^\circ & \cos 90^\circ \end{pmatrix} = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$$


MODIFICANDO A IDENTIDADE...

$$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$\begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$ Escalona em torno do ponto $(0,0)$

$\begin{pmatrix} -1 & 0 \\ 0 & 2 \end{pmatrix}$ Escalona em torno do ponto $(0,0)$ na direção y e gira em torno de y


$\begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}$ Gira em torno do ponto $(0,0)$, ie, em torno de x e y .



$$\begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 3 \end{pmatrix}$$

$$\begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$$




Distorção
 $\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$

$$\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$


$$\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$



Rotação:
 $\begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$

E SE EU QUISER TRANSLADAR ???



Ao multiplicar um vetor 2D por uma matriz 2x2 qualquer, você não consegue transladá-lo.


Na transformação linear: escalonamento, distorção e rotação, os vetores de base permanecem todos na mesma origem (0,0) antes e depois da transformação.

Isso significa que o ponto (0,0) nunca muda de localização. Para transladar, você precisa adicionar um vetor após a transformação da matriz...


$$\begin{bmatrix} q_1 \\ q_2 \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \begin{bmatrix} p_1 \\ p_2 \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

nova localização após
a transformação
ANÁLISE ESTATÍSTICA DE DADOS

localização
original



TRANSFORMAÇÃO GEOMÉTRICA DA IMAGEM



Envie cada pixel p da posição original (x, y)
para a correspondente posição
 $(x', y') = T(x, y)$ na imagem transformada

Escalonamento,
distorção e rotação


Translação



$$\begin{bmatrix} q_1 \\ q_2 \\ 1 \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & l \\ a_{21} & a_{22} & l \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} p_1 \\ p_2 \\ 1 \end{bmatrix}$$

Fixando a imagem no plano $z = 1$

PORTANTO...




$$\begin{pmatrix} 1 & 0 & \color{red}{3} \\ 0 & 1 & \color{red}{2} \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 2 \\ 1 \end{pmatrix}$$





$$\begin{pmatrix} 1 & 0 & \color{red}{3} \\ 0 & 1 & \color{red}{2} \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 0 & \color{red}{3} \\ 0 & 1 & \color{red}{2} \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 3 \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 0 & \color{red}{3} \\ 0 & 1 & \color{red}{2} \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \\ 1 \end{pmatrix}$$




TRANSLAÇÃO, ESCALONAMENTO E ROTAÇÃO



DISTORÇÃO


DISTORÇÃO EM TORNO
EIXO X

$$\begin{bmatrix} 1 & \tan \phi & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$




DISTORÇÃO EM TORNO
EIXO Y

$$\begin{bmatrix} 1 & 0 & 0 \\ \tan \psi & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$




REFLEXÃO


REFLEXÃO EM
TORNO DA ORIGEM



EM TORNO EIXO X



EM TORNO EIXO Y



POR EXEMPLO...


Sabendo que a figura do Wall-E ao lado sofreu seguinte transformação,

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = T \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \text{ onde } T \text{ é composta das matrizes}$$

de escalonamento e rotação, respectivamente,

$$S = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}, R = \begin{pmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Defina a matriz T para as seguintes transformações,



POR EXEMPLO...

$$S = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}, R = \begin{pmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Defina a matriz T para as seguintes transformações,



() $T = S$
() $T = R$



() $T = S$
() $T = R$



() $T = SR$
() $T = RS$



() $T = RS$
() $T = RS$



Stop waiting to *feel* ready.

Ready is not a *feeling*.

It's a *decision*.

ACABOU... REVEJAM O MATERIAL
DISPONIBILIZADO EM AULA.
REFÂÇAM EXERCÍCIOS

Bom carnaval!