

# Análise Estatística de dados

## Inteligência Artificial




### AULA 04 – DECOMPOSIÇÃO DE VALOR SINGULAR

Larissa Driemeier


# PROGRAMA DO CURSO

Aula	Data	Conteúdo da Aula
01	18/02	Aula Inaugural
02	25/02	Introdução ao Curso. Noções de Álgebra Linear , Geometria Analítica Parte I
03	11/03	Noções de Álgebra Linear , Geometria Analítica Parte II
04	18/03	Decomposição de valor singular (SVD)
05	25/03	Otimização: derivadas, derivadas parciais (operadores gradiente, Jacobiano, Hessiano e Laplaciano), algoritmos de gradiente, noções de algoritmos genéticos
06	01/04	Variáveis independentes e não independentes. Estatística Descritiva e Indutiva. Definições de medidas de dispersão e tendência central.
07	08/04	Probabilidade e Teorema de Bayes
08	15/04	Modelos de probabilidade discretos/contínuos
09	22/04	Intervalo de confiança e teste de hipóteses
10	29/04	Modelo de Markov. Modelo de Markov oculto.

# TRANSFORMAÇÃO



$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$



Suponha que a transformação  $T(x) = Ax$  seja aplicada a um círculo de raio unitário centrado na origem.

# AUTOVETORES E AUTOVALORES

$$A = \begin{pmatrix} 3 & 2 \\ 0 & 2 \end{pmatrix}$$

$$\det A = 6, \operatorname{tr} A = 5$$

$$\lambda^2 - 5\lambda + 6 = 0$$

## AUTOVALORES

$$\begin{aligned} \lambda_1 &= 3 \\ \lambda_2 &= 2 \end{aligned}$$

## AUTOVETORES

$$u_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$


$$u_2 = \begin{pmatrix} -0,8944 \\ 0,4472 \end{pmatrix}$$

$$T = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$

$$\lambda_1 = 3 \quad \lambda_2 = 2$$


$$u_1 = (1, 0) \quad u_2 = (0.89, -0.45)$$

$$\det T = 6$$




Brinque no link: <https://www.geogebra.org/classic/mdvN0HTt>


Transformação do autovetor  $(0,89;-0,45)$  com autovalor 2.



Transformação do autovetor  $(1,0)$  com autovalor 3.



# AUTOVETORES



$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$

$$u_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, u_2 = \begin{bmatrix} -0,8944 \\ 0,4472 \end{bmatrix}$$

$$\lambda_1 = 3, \quad \lambda_2 = 2$$

[https://github.com/reza-bagheri/SVD\\_article](https://github.com/reza-bagheri/SVD_article)

Os vetores  $u_i$  são os autovetores de  $A$ ; os escalares  $\lambda_i$  são chamados autovalores.

EM PYTHON  $A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$

```
A = np.array([[3,2],[0,2]])  
# Cálculo de autovalores e autovetores  
lam, u = linalg.eig(A)  
print("autovalores=\n", np.round(lam, 4))  
print("autovetores=\n", np.round(u, 4))
```

```
autovalores=  
[3. 2.]  
autovetores=  
[[ 1. -0.8944]  
 [ 0.  0.4472]]
```





EM PYTHON  $A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$



```
A = np.array([[3,1],[1,2]])  
# Cálculo de autovalores e autovetores  
lam, u = linalg.eig(A)  
print("autovalores=\n", np.round(lam, 4))  
print("autovetores=\n", np.round(u, 4))
```

```
autovalores=  
[3.618 1.382]  
autovetores=  
[[ 0.8507 -0.5257]  
 [ 0.5257 0.8507]]
```

$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$




$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$




# INTUIÇÃO GEOMÉTRICA PARA MATRIZ 2X2 SIMÉTRICA QUADRADA

Direções de  
alongamentos  
principais



Eixo secundário

Eixo principal



# PROBLEMA DE AUTOVALORES E MATRIZES SIMÉTRICAS


Duas propriedades importantes surgem quando olhamos para os autovalores e autovetores de uma matriz simétrica  $A_{n \times n}$ ,

- todos  $n$  os autovalores de  $A$  são reais;
- os  $n$  autovetores de  $A$  são ortonormais, ou seja, a matriz composta dos autovetores é uma matriz ortogonal.

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 0,8 \end{bmatrix}$$

```
A = np.array([[3, 1],
              [1, 0.8]])
# Cálculo de autovalores e autovetores
lam, u = linalg.eig(A)
print("autovalores=\n", np.round(lam, 4))
print("autovetores=\n", np.round(u, 4))
```

```
autovalores=
[3.3866 0.4134]
autovetores=
[[ 0.9327 -0.3606]
 [ 0.3606 0.9327]]
```



# DECOMPOSIÇÃO EM AUTOVALORES

Toda matriz **simétrica quadrada** pode ser decomposta em,

$$A = USU^T$$

$$A = \begin{pmatrix} | & | & & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_n \\ | & | & & | \end{pmatrix} \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_n \end{pmatrix} \begin{pmatrix} - & \mathbf{u}_1^T & - \\ - & \mathbf{u}_2^T & - \\ & \vdots & \\ - & \mathbf{u}_n^T & - \end{pmatrix}$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

onde  $\mathbf{u}_i$  são  $n$  LI autovetores de  $A$  e  $\lambda_i$  são os autovalores de  $A$

# POR EXEMPLO

$$A = \begin{pmatrix} 7 & 3 \\ 3 & -1 \end{pmatrix}$$

$$\det A = -16, \operatorname{tr} A = 6$$

$$\lambda^2 - 6\lambda - 16 = 0$$

```
A = np.array([[7,3],[3,-1]])  
# Cálculo de autovalores e autovetores  
lam, u = linalg.eig(A)  
print("autovalores=\n", np.round(lam, 4))  
print("autovetores=\n", np.round(u, 4))
```

```
autovalores=  
[ 8. -2.]  
autovetores=  
[[ 0.9487 -0.3162]  
 [ 0.3162  0.9487]]
```

$$\lambda_1 = 8$$

$$\lambda_2 = -2$$

$$u_1 = \begin{pmatrix} 0,9487 \\ 0,3162 \end{pmatrix}$$

$$u_2 = \begin{pmatrix} -0,3162 \\ 0,9487 \end{pmatrix}$$

# POR EXEMPLO...

$$A = \begin{pmatrix} 7 & 3 \\ 3 & -1 \end{pmatrix}$$

$$\lambda_1 = 8 \rightarrow u_1 = \begin{pmatrix} 0,9487 \\ 0,3162 \end{pmatrix}$$

$$\lambda_2 = -2 \rightarrow u_2 = \begin{pmatrix} -0,3162 \\ 0,9487 \end{pmatrix}$$

$$A = USU^T$$

$$A = \begin{pmatrix} | & | \\ u_1 & u_2 \\ | & | \end{pmatrix} \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \begin{pmatrix} - & u_1^T & - \\ - & u_2^T & - \end{pmatrix}$$

$$U = \begin{pmatrix} 0,9487 & -0,3162 \\ 0,3162 & 0,9487 \end{pmatrix} \quad S = \begin{pmatrix} 8 & 0 \\ 0 & -2 \end{pmatrix}$$

$$A = \begin{pmatrix} 0,9487 & -0,3162 \\ 0,3162 & 0,9487 \end{pmatrix} \begin{pmatrix} 8 & 0 \\ 0 & -2 \end{pmatrix} \begin{pmatrix} 0,9487 & 0,3162 \\ -0,3162 & 0,9487 \end{pmatrix}$$

$$A = \begin{pmatrix} 0,9487 \times 8 + (-0,3162) \times 0 & 0,9487 \times 0 + (-0,3162) \times (-2) \\ 0,3162 \times 8 + 0,9487 \times 0 & 0,3162 \times 0 + 0,9487 \times (-2) \end{pmatrix} \begin{pmatrix} 0,9487 & 0,3162 \\ -0,3162 & 0,9487 \end{pmatrix}$$

$$A = \begin{pmatrix} 7,5896 & 0,6324 \\ 2,5296 & -1,8974 \end{pmatrix} \begin{pmatrix} 0,9487 & 0,3162 \\ -0,3162 & 0,9487 \end{pmatrix} = \begin{pmatrix} 7,0002 & 2,9998 \\ 2,9998 & -1,0002 \end{pmatrix}$$



```
A = np.array([[3, 1],
              [1, 2]])
lam, u = linalg.eig(A)
print("autovalores=\n", np.round(lam, 4))
print("autovetores=\n", np.round(u, 4))
S=np.array([[lam[0], 0],
            [0, lam[1]]])

u1 = np.array(u[:,0])
u2 =np.array(u[:,1])
P=np.array([u1,u2]).T

t = P @ S @ P.T
print("Recupera-se a matriz A\n",t)
```

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

```
autovalores=
[3.618 1.382]
autovetores=
[[ 0.8507 -0.5257]
 [ 0.5257 0.8507]]
Recupera-se a matriz
A [[3. 1.]
   [1. 2.]]
```

REPRE QUE...

$$A = U \mathbf{S} U^T \rightarrow \mathbf{S} U^T$$

$$A = \begin{pmatrix} | & | \\ \mathbf{u}_1 & \mathbf{u}_2 \\ | & | \end{pmatrix} \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \begin{pmatrix} - & \mathbf{u}_1^T & - \\ - & \mathbf{u}_2^T & - \end{pmatrix}$$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \\ \vdots \\ \mathbf{u}_n^T \end{bmatrix} =$$

$$\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & \dots & u_{1n} \\ u_{21} & u_{22} & \dots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ u_{n1} & u_{n2} & \dots & u_{nn} \end{bmatrix} =$$

$$\begin{bmatrix} \lambda_1 u_{11} & \lambda_1 u_{12} & \dots & \lambda_1 u_{1n} \\ \lambda_2 u_{21} & \lambda_2 u_{22} & \dots & \lambda_2 u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_n u_{n1} & \lambda_n u_{n2} & \dots & \lambda_n u_{nn} \end{bmatrix} = \begin{bmatrix} \lambda_1 \mathbf{u}_1^T \\ \lambda_2 \mathbf{u}_2^T \\ \vdots \\ \lambda_n \mathbf{u}_n^T \end{bmatrix}$$

PORTANTO...

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{U}^T$$


$$\mathbf{A} = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n] \begin{bmatrix} \lambda_1 \mathbf{u}_1^T \\ \lambda_2 \mathbf{u}_2^T \\ \vdots \\ \lambda_n \mathbf{u}_n^T \end{bmatrix} =$$




$$\mathbf{A} = \lambda_1 \mathbf{u}_1 \mathbf{u}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{u}_2^T + \dots + \lambda_n \mathbf{u}_n \mathbf{u}_n^T$$

Portanto, a matriz  $\mathbf{A}$  pode ser decomposta em  $n$  matrizes  $\mathbf{u}_i \mathbf{u}_i^T$   $n \times n$  ponderadas de  $\lambda_i$

# VAMOS DEVAGAR PARA ENTENDER...




Suponha um vetor  $x$  qualquer, e aplicamos uma matriz  $A$  de transformação, simétrica  $n \times n$ .



<https://towardsdatascience.com/understanding-singular-value-decomposition-and-its-application-in-data-science-388a54be95d>

$$Ax = \lambda_1 u_1 u_1^T x + \lambda_2 u_2 u_2^T x$$

# PROJEÇÃO




Dimensão da  
componente de  
 $x$  ao longo de  $u$

$$p = \frac{u}{u^T u} u^T x$$


Vetor  $u$   
normalizado  
dá a direção  
de  $p$

$$Ax = \lambda_1 u_1 u_1^T x + \lambda_2 u_2 u_2^T x + \cdots + \lambda_n u_n u_n^T x$$

$u_i u_i^T x \rightarrow$  Projeta o vetor  $x$  na  $i$ -ésima direção principal!!!



$$Ax = \lambda_1 u_1 u_1^T x + \lambda_2 u_2 u_2^T x$$



Uma matriz simétrica transforma um vetor alongando-o ou encolhendo-o ao **longo de seus autovetores**.

Além disso, sabemos que as matrizes transformam um autovetor **multiplicando seu comprimento (ou magnitude) pelo autovalor correspondente**.

# INSIGHT...

$$A = \lambda_1 \mathbf{u}_1 \mathbf{u}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{u}_2^T + \cdots + \lambda_k \mathbf{u}_k \mathbf{u}_k^T + \cdots + \lambda_n \mathbf{u}_n \mathbf{u}_n^T$$

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_k \cdots \geq \lambda_n \geq 0$$

Quanto maior o autovalor, maior o comprimento do vetor resultante  $\lambda_i \mathbf{u}_i \mathbf{u}_i^T$  e mais peso é dado à sua matriz correspondente  $\mathbf{u}_i \mathbf{u}_i^T$ .


Assim, podemos aproximar nossa matriz simétrica original  $A$  somando os termos que têm os maiores autovalores,

$$A \approx \lambda_1 \mathbf{u}_1 \mathbf{u}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{u}_2^T + \cdots + \lambda_k \mathbf{u}_k \mathbf{u}_k^T$$

$$A \approx A_1 + A_2 + \cdots + A_k$$

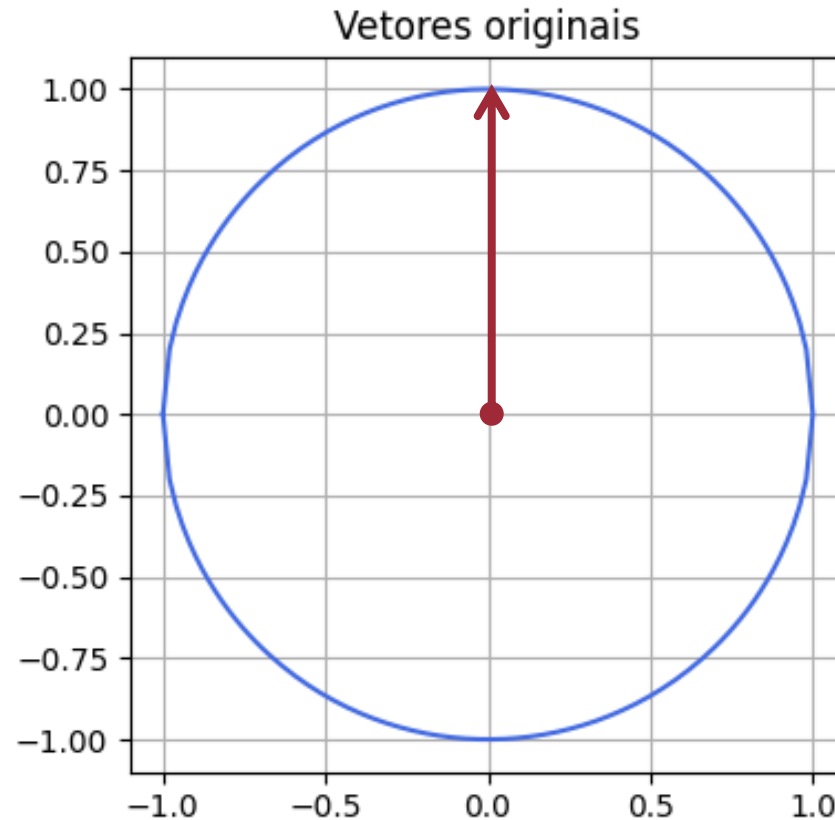
onde  $A_i$  é uma matriz de projeção e deve projetar tudo em  $\mathbf{u}_i$ .

[https://github.com/reza-bagheri/SVD\\_article](https://github.com/reza-bagheri/SVD_article)



# DECOMPONHA $A$ E ACHE A PROJEÇÃO $A_1$

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$





# AUTOVALORES E AUTOVETORES DE $A$

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

$$u_1 = \begin{bmatrix} 0.8507 \\ 0.5257 \end{bmatrix}, \lambda_1 = 3.618$$

$$u_2 = \begin{bmatrix} -0.5257 \\ 0.8507 \end{bmatrix}, \lambda_2 = 1.382$$

```
1 # Cálculo de autovalores e autovetores
2 #A = np.array([[3, 2],
3 #             [0, 2]])
4 A = np.array([[3, 1],
5             [1, 2]])
6 lam, u = linalg.eig(A)
7 print("autovalores=", np.round(lam, 4))
8 print("autovetores=", np.round(u, 4))
9
```


```
autovalores= [3.618 1.382]
autovetores= [[ 0.8507 -0.5257]
 [ 0.5257  0.8507]]
```

# AUTOVALORES E AUTOVETORES DE $A$

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

$$u_1 = \begin{bmatrix} 0.8507 \\ 0.5257 \end{bmatrix}, \lambda_1 = 3.618$$

$$u_2 = \begin{bmatrix} -0.5257 \\ 0.8507 \end{bmatrix}, \lambda_2 = 1.382$$



$$A = USU^T$$

$$A = \begin{pmatrix} | & | \\ \mathbf{u}_1 & \mathbf{u}_2 \\ | & | \end{pmatrix} \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \begin{pmatrix} - & \mathbf{u}_1^T & - \\ - & \mathbf{u}_2^T & - \end{pmatrix}$$

$$\mathbf{u}_1 = \begin{bmatrix} 0.8507 \\ 0.5257 \end{bmatrix}, \lambda_1 = 3.618$$

$$\mathbf{u}_2 = \begin{bmatrix} -0.5257 \\ 0.8507 \end{bmatrix}, \lambda_2 = 1.382$$

$$S = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} = \begin{bmatrix} 3.618 & 0 \\ 0 & 1.382 \end{bmatrix}$$

$$U = \begin{bmatrix} 0.8507 & -0.5257 \\ 0.5257 & 0.8507 \end{bmatrix}$$


$$U^T = [\mathbf{u}_1 \quad \mathbf{u}_2]^T = \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \end{bmatrix} = \begin{bmatrix} 0.8507 & 0.5257 \\ -0.5257 & 0.8507 \end{bmatrix}$$

DECOMPOSIÇÃO




$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} 0.8507 & -0.5257 \\ 0.5257 & 0.8507 \end{bmatrix} \begin{bmatrix} 3.618 & 0 \\ 0 & 1.382 \end{bmatrix} \begin{bmatrix} 0.8507 & 0.5257 \\ -0.5257 & 0.8507 \end{bmatrix}$$

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$




$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$



$$A_1 = \lambda_1 u_1 u_1^T = 3.61 \begin{bmatrix} 0.8507 \\ 0.5257 \end{bmatrix} \begin{bmatrix} 0.8507 & 0.5257 \end{bmatrix} = \begin{bmatrix} 2.618 & 1.618 \\ 1.618 & 1 \end{bmatrix}$$

$$A_2 = \lambda_2 u_2 u_2^T = 1.382 \begin{bmatrix} -0.5257 \\ 0.8507 \end{bmatrix} \begin{bmatrix} -0.5257 & 0.8507 \end{bmatrix} = \begin{bmatrix} 0.382 & -0.618 \\ -0.618 & 1 \end{bmatrix}$$



# FAÇA VOCÊ: ENCONTRE A PROJEÇÃO $A_1$

$$A = \begin{pmatrix} 5 & 2 \\ 2 & 1 \end{pmatrix}$$

$$u_1 = \begin{bmatrix} 0.9239 \\ 0.3287 \end{bmatrix}, \lambda_1 = 5.8284$$


$$u_2 = \begin{bmatrix} -0.3827 \\ 0.9239 \end{bmatrix}, \lambda_2 = 0.1716$$

$$A_1 = \lambda_1 u_1 u_1^T = \begin{bmatrix} 4.9749 & 2.0607 \\ 2.0606 & 0.8535 \end{bmatrix}$$


```
1 A = np.array([[5, 2],
2               [2,1]])
3 lam, u = linalg.eig(A)
4 print("autovalores=\n", np.round(lam, 4))
5 print("autovetores=\n", np.round(u, 4))
6 S=np.array([[lam[0], 0],
7             [0, lam[1]]])
8 u1 = np.array(u[:,0])
9 u2 =np.array(u[:,1])
10 P=np.array([u1,u2]).T
11
12
13 t = P @ S @ P.T
14 print("Recupera-se a matriz A\n",t)
```

```
autovalores=
[5.8284 0.1716]
autovetores=
[[ 0.9239 -0.3827]
 [ 0.3827  0.9239]]
Recupera-se a matriz A
[[5. 2.]
 [2. 1.]]
```

Vetores originais




Novos vetores após transformação







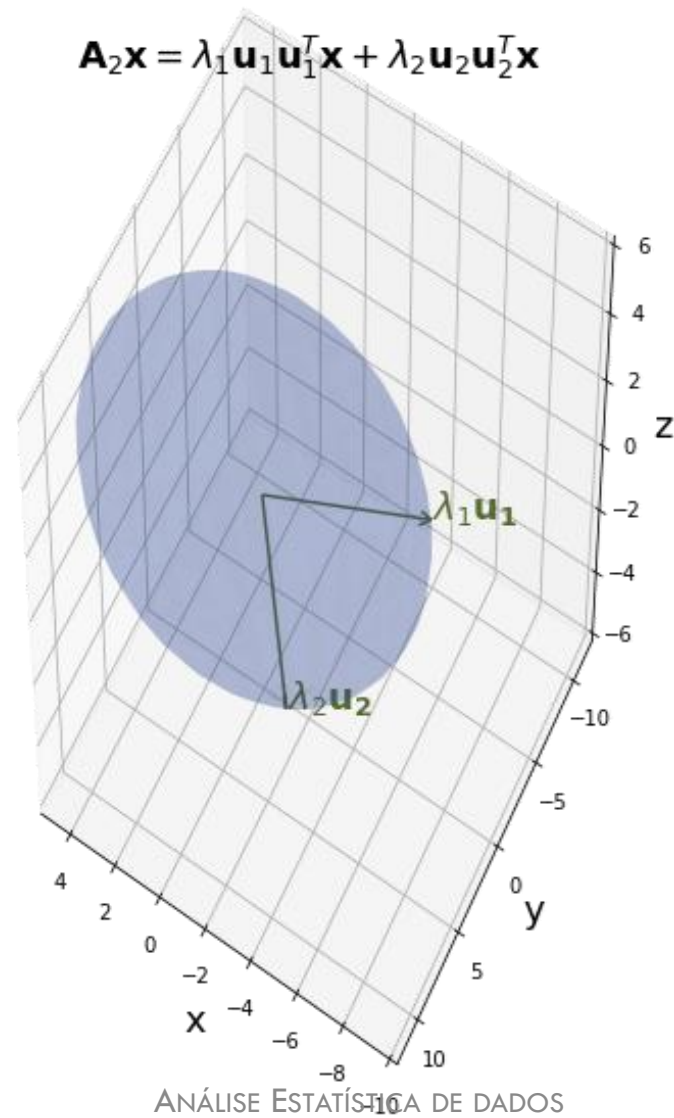

Vetores originais



Como você vê, o círculo inicial é alongado ao longo de  $u_1$  e reduzido a zero ao longo de  $u_2$ . Portanto, o resultado dessa transformação é uma linha reta, não uma elipse.

Novos vetores após transformação







Se você tiver não uma matriz quadrada  
simétrica, não poderá usar o método de  
composição por autovalores para  
aproximar matrizes...



E a maioria das matrizes que você irá  
trabalhar não são nem quadradas e  
nem simétricas...



# VALORES SINGULARES

Antes de falar em SVD devemos encontrar uma maneira de calcular as direções de alongamento para uma matriz não simétrica.



# MATRIZ $A^T A$

$$(A^T A)^T = A^T (A^T)^T = A^T A$$



$A$  é uma matriz  $m \times n$  e não necessariamente simétrica.

A matriz  $A^T A$  é quadrada ( $n \times n$ ) e simétrica e possui autovetores  $v_i$  ortogonais e autovalores  $\lambda_i$




Vamos assumir que os vetores  $v_i$  estão normalizados, ie,  
 $\|v_i\|^2 = v_i^T v_i = 1$



# $A\mathbf{v}_i$

$$\|A\mathbf{v}_i\|^2 = (A\mathbf{v}_i)^T A\mathbf{v}_i = \mathbf{v}_i^T \boxed{A^T A \mathbf{v}_i}$$

Lembre-se que  $\mathbf{v}_i$  são autovetores de  $A^T A$ . Portanto,  
 $A^T A \mathbf{v}_i = \lambda_i \mathbf{v}_i$



$$\|A\mathbf{v}_i\|^2 = \mathbf{v}_i^T \boxed{\lambda_i \mathbf{v}_i} = \lambda_i \boxed{\mathbf{v}_i^T \mathbf{v}_i} \quad \mathbf{v}_i^T \mathbf{v}_i = 1$$


$$\|A\mathbf{v}_i\|^2 = \lambda_i$$

Veja que daqui se pode deduzir que todos os autovetores de  $A^T A$  são positivos

$$\|A\mathbf{v}_i\| = \sqrt{\lambda_i} = \sigma_i$$

$\sigma_i$  são os comprimentos dos vetores  $A\mathbf{v}_i$  e são chamados de **valores singulares de  $A$** .

# CHEGAMOS AO PONTO CHAVE DO MÉTODO SVD



Fazendo papel de  $u_i$  da  
matriz simétrica.




Pode-se provar que  $Av_i$  são  
ortogonais e representam as  
direções principais de  
alongamento da transformação  $A$   
sobre  $\|x\| = 1$ , de comprimento

$$\|Av_i\| = \sigma_i$$

Já calculamos  
anteriormente.

# EXEMPLO

$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$



<https://www.geogebra.org/classic/mdvN0HTt>



# EXEMPLO


$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$



$$A^T A = \begin{bmatrix} 9 & 6 \\ 6 & 8 \end{bmatrix}$$

$$v_1 = \begin{bmatrix} 0.7359 \\ 0.6771 \end{bmatrix}, \lambda_1 = 14.5208$$

$$v_2 = \begin{bmatrix} -0.6771 \\ 0.7359 \end{bmatrix}, \lambda_2 = 2.4792$$



$$Av_1 = \begin{bmatrix} 3.5619 \\ 1.3542 \end{bmatrix}$$

$$Av_2 = \begin{bmatrix} -0.5596 \\ 1.4718 \end{bmatrix}$$

# RANK DE $A$

Suponha que o número de valores singulares diferentes de zero seja  $r$ . Eles são todos positivos e podemos ordená-los em forma decrescente, como


$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$$

que correspondem a

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r$$

e cada  $\lambda_i$  é o autovalor correspondente de  $\mathbf{v}_i$ .

Então pode-se mostrar que o rank de  $A$ , que é o número de vetores que formam a base de  $A\mathbf{x}$ , é  $r$ . Pode-se mostrar também que o conjunto  $A\mathbf{v}_i$ ,  $\{A\mathbf{v}_1, A\mathbf{v}_2, \dots, A\mathbf{v}_r\}$  é uma base ortogonal para  $A\mathbf{x}$ .






# DECOMPOSIÇÃO EM VALORES SINGULARES

SVD

# QUAL A IDEIA DA DECOMPOSIÇÃO EM VALORES SINGULARES???






Define-se:

$$u_1 = \frac{Av_1}{\|Av_1\|} = \frac{Av_1}{\sigma_1}$$

$$u_2 = \frac{Av_2}{\|Av_2\|} = \frac{Av_2}{\sigma_2}$$


como versores nas direções de  $Av_1$  e  $Av_2$ .





$$Av_1 = \sigma_1 u_1$$


$$Av_2 = \sigma_2 u_2$$



Os comprimentos de  $Av_1$  e  $Av_2$ , que são  $\sigma_1$  e  $\sigma_2$ , descrevem a dimensão das transformações que ocorrem, respectivamente, nas direções  $u_1$  e  $u_2$ .

# E SE APLICARMOS $A$ EM UM VETOR $x$ QUALQUER?

$Ax = ?$



$$x = (x \cdot v_1)v_1 + (x \cdot v_2)v_2$$

$$Ax = Av_1(x \cdot v_1) + Av_2(x \cdot v_2)$$



$$Av_1 = \sigma_1 u_1$$

$$Av_2 = \sigma_2 u_2$$

$$Ax = \sigma_1 u_1 (x \cdot v_1) + \sigma_2 u_2 (x \cdot v_2)$$

$$Ax = \sigma_1 u_1 v_1^T x + \sigma_2 u_2 v_2^T x$$

$$Ax = (\sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T) x$$

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T$$

# E $u_i$ E $v_i$ ? O QUE PODEMOS CONCLUIR DELES?

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T$$

Sabemos que  $v_i$  são autovetores de  $A^T A$

$$A^T A v_1 = A^T [\sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T] v_1$$

$$A^T A v_1 = A^T \sigma_1 u_1$$

$$A^T A v_1 = [\sigma_1 v_1 u_1^T + \sigma_2 v_2 u_2^T] \sigma_1 u_1$$

$$A^T A v_1 = \sigma_1^2 v_1$$

Analogamente,

$$A^T A v_2 = \lambda_2 v_2 = \sigma_2^2 v_2$$

Opa!!!!  $u_i$  são autovetores de  $A A^T$

$$A A^T = \sigma_1 u_1 v_1^T A^T + \sigma_2 u_2 v_2^T A^T$$

$$A A^T = \sigma_1 u_1 v_1^T \sigma_1 v_1 u_1^T + \sigma_2 u_2 v_2^T \sigma_2 v_2 u_2^T$$

$$A A^T = \sigma_1^2 u_1 u_1^T + \sigma_2^2 u_2 u_2^T$$

$$A A^T u_1 = \sigma_1^2 u_1 u_1^T u_1 + \sigma_2^2 u_2 u_2^T u_1$$

$$A A^T u_1 = \sigma_1^2 u_1$$

Analogamente,

$$A A^T u_2 = \lambda_2 u_2 = \sigma_2^2 u_2$$

# EM RESUMO


$\mathbf{v}_i$  são autovetores da transformação  $\mathbf{A}^T \mathbf{A}$ ;  $\mathbf{u}_i$  são autovetores da transformação  $\mathbf{A} \mathbf{A}^T$

$\sigma_i$  é a raiz quadrada dos autovalores da transformação  $\mathbf{A}^T \mathbf{A}$  ou  $\mathbf{A} \mathbf{A}^T$

$\mathbf{u}_i$  são os vetores unitários na direção  $\mathbf{A} \mathbf{v}_i$ , de forma que  $\mathbf{u}_i = \mathbf{A} \mathbf{v}_i / \sigma_i$

O primeiro vetor  $\mathbf{u}_1 = \mathbf{A} \mathbf{v}_1 / \sigma_1$  aponta para a direção mais importante dos dados.



$\sigma_i$  é usado para dar um peso à direção  $\mathbf{u}_i \rightarrow \mathbf{A} \mathbf{v}_i = \sigma_i \mathbf{u}_i$





# INTERPRETAÇÃO FINAL

$$Ax = \sigma_1 u_1 v_1^T x + \sigma_2 u_2 v_2^T x$$





# VETORES E VALORES SINGULARES

Definição final

# VETORES E VALORES SINGULARES

Dada uma matriz  $A \in \mathbb{R}^{m \times n}$ , as matrizes à esquerda e à direita de  $A$  são, respectivamente,

$$\underset{m \times m}{AA^T} \text{ e } \underset{n \times n}{A^T A}.$$

As matrizes  
 $AA^T$  e  
 $A^T A$  têm os  
mesmos  
autovalores  
não nulos.

$AA^T$  e  $A^T A$  são simétricas, reais e quadradas. Portanto, autovalores  $AA^T$  ou  $A^T A$  são reais não negativos, iguais ou distintos.

# VALORES SINGULARES DE UMA MATRIZ

Chamamos de **valores singulares** da matriz  $A$ , as  $r$  raízes quadradas dos autovalores  $\lambda_1, \lambda_2, \dots, \lambda_r$  não nulos de  $AA^T$  ou  $A^T A$ ;

$$\sigma_i = \sqrt{\lambda_i}$$

Os **vetores singulares**  $u_i$  à esquerda da matriz  $A$  são os autovetores de  $AA^T, m \times m$ .

Os **vetores singulares**  $v_i$  à direita da matriz  $A$  são os autovetores de  $A^T A, n \times n$ .

# MATRIZES $U$ E $V$

Os autovetores de  $AA^T$  formam as colunas da matriz  $U$  e os autovetores de  $A^T A$  formam as colunas da matriz  $V$ . Como são simétricos, os autovetores são perpendiculares entre si e podem ser definidos com comprimento unitário, de forma que:

$$U^T U = I \qquad V^T V = I$$

# POR EXEMPLO...

$$\mathbf{A} = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$$

$$\mathbf{A}^T \mathbf{A} = \begin{pmatrix} 13 & 12 & 2 \\ 12 & 13 & -2 \\ 2 & -2 & 8 \end{pmatrix}$$

$$|\mathbf{A}^T \mathbf{A} - \lambda \mathbf{I}| = 0$$

$$\lambda^3 - 34\lambda^2 + 225\lambda = \lambda(9 - \lambda)(25 - \lambda) = 0$$

$$\lambda_1 = 25, \quad \lambda_2 = 9, \quad \lambda_3 = 0$$

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{25} = 5$$

$$\sigma_2 = \sqrt{\lambda_2} = \sqrt{9} = 3$$

$$\sigma_3 = \sqrt{\lambda_3} = 0$$

$$\mathbf{A} \mathbf{A}^T = \begin{pmatrix} 17 & 8 \\ 8 & 17 \end{pmatrix}$$

$$|\mathbf{A} \mathbf{A}^T - \lambda \mathbf{I}| = 0$$

$$\lambda^2 - 34\lambda + 225 = (25 - \lambda)(9 - \lambda)$$

$$\lambda_1 = 25, \quad \lambda_2 = 9$$

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{25} = 5$$

$$\sigma_2 = \sqrt{\lambda_2} = \sqrt{9} = 3$$

# AUTOVETORES...

$$(AA^T - \lambda_i I)u_i = 0$$

Por exemplo, para  $\lambda = 25$ ,

$$AA^T - 25I = \begin{pmatrix} 17 - 25 & 8 \\ 8 & 17 - 25 \end{pmatrix} = \begin{pmatrix} -8 & 8 \\ 8 & -8 \end{pmatrix}$$

$$\begin{pmatrix} -8 & 8 \\ 8 & -8 \end{pmatrix} \begin{pmatrix} u_{1,1} \\ u_{2,1} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \longrightarrow \quad u_1 = \begin{pmatrix} u_{1,1} \\ u_{2,1} \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

Analogamente:  $u_2 = \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$

$$U = \begin{bmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$$

$$(A^T A - \lambda_i I) v_i = 0$$

Por exemplo, para  $\lambda = 25$ ,

$$A^T A - 25I = \begin{pmatrix} 13 - 25 & 12 & 2 \\ 12 & 13 - 25 & -2 \\ 2 & -2 & 8 - 25 \end{pmatrix} = \begin{pmatrix} -12 & 12 & 2 \\ 12 & -12 & -2 \\ 2 & -2 & -17 \end{pmatrix}$$

$$\begin{pmatrix} -12 & 12 & 2 \\ 12 & -12 & -2 \\ 2 & -2 & -17 \end{pmatrix} \begin{pmatrix} v_{1,1} \\ v_{2,1} \\ v_{3,1} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \quad \longrightarrow \quad v_1 = \begin{pmatrix} v_{1,1} \\ v_{2,1} \\ v_{3,1} \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \\ 0 \end{pmatrix}$$

$$-6v_{1,1} + 6v_{2,1} + v_{3,1} = 0$$

$$2v_{1,1} - 2v_{2,1} - 17v_{3,1} = 0$$

$$v_{1,1}^2 + v_{2,1}^2 + v_{3,1}^2 = 1$$

$$V = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{18} & 2/3 \\ 1/\sqrt{2} & -1/\sqrt{18} & -2/3 \\ 0 & 4/\sqrt{18} & -1/3 \end{bmatrix}$$



# MATRIZES ORTOGONAIS $U$ E $V$

$$V = \begin{pmatrix} | & | & \dots & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_n \\ | & | & & | \end{pmatrix}$$

$n \times n$

$$U = \begin{pmatrix} | & | & \dots & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_m \\ | & | & & | \end{pmatrix}$$

$m \times m$

onde  $\mathbf{v}_i$  são os autovetores de  $A^T A$  e  $\mathbf{u}_i$  são os autovetores de  $AA^T$

$$\begin{matrix} \sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m \\ | & & & | \\ \begin{pmatrix} | & | & \dots & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_m \\ | & | & & | \end{pmatrix} \end{matrix}$$




# SVD

Definição

# SVD

$$A = \sigma_1 u_1 v_1^T + \dots + \sigma_r u_r v_r^T$$

$$A_{m \times n} = U_{m \times m} S_{m \times n} V_{n \times n}^T$$



$A_{m \times n}$  é uma matriz de valores reais

$U_{m \times m}$  é uma matriz ortogonal

$S_{m \times n}$  é uma matriz diagonal

$V_{n \times n}^T$  é uma matriz ortogonal

# DECOMPOSIÇÃO EM VALORES SINGULARES

O **SVD (Singular Value Decomposition)** é um método para fatorar matrizes:

$$A = USV^T = U \begin{bmatrix} D_{r \times r} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}_{m \times n} V^T$$

onde  $U$  e  $V$  são as matrizes ortogonais que definimos e  $S$  é diagonal.

Os valores da matriz diagonal  $S$  são os valores singulares  $\sigma_i$  que acabamos de aprender, e por isso a decomposição recebe este nome.

O número de valores singulares diferentes de zero é igual ao rank da matriz  $A$ .

# MATRIZ DIAGONAL $S$

Se  $A$  tem  $r$  valores singulares não nulos,  $S$  é uma matriz da forma:


$$S = \begin{matrix} D_{r \times r} & \begin{pmatrix} \sigma_1 & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & \ddots & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & \sigma_r & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \end{matrix}$$

Em SVD, os elementos diagonais da matriz  $S$ , ié, os valores singulares  $\sigma_i$ , são computados em ordem decrescente  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$


# OU SEJA...

$$A = \begin{pmatrix} 3 & 7 \\ 5 & 2 \end{pmatrix} = USV^T = \begin{bmatrix} -0,8506 & -0,52573 \\ -0,52573 & 0,8506 \end{bmatrix} \begin{bmatrix} 8,7134 & 0 \\ 0 & 3,3282 \end{bmatrix} \begin{bmatrix} -0,5945 & -0,8040 \\ 0,8040 & -0,5945 \end{bmatrix}$$


$$A = \begin{pmatrix} 3 & 7 \\ 5 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$




Círculo inicial



Rodado pela matriz  $V$




Escalonado pela matriz  $S$




Rodado pela matriz  $U$


# PORTANTO...



Rodado pela matriz  $V$



Escalonado pela matriz  $S$



Rodado pela matriz  $U$

$A$  é uma matriz que pode ser vista como uma transformação linear. Essa transformação pode ser decomposta em três sub-transformações: rotação, escalonamento, rotação. Esses três passos correspondem às três matrizes:  $U$ ,  $S$  e  $V$ .

# VEJA QUE ...

$$A_{m \times n} = \begin{pmatrix} \mathbf{a}_{11} & \mathbf{a}_{12} & \cdots & \mathbf{a}_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_{m1} & \mathbf{a}_{m2} & \cdots & \mathbf{a}_{mn} \end{pmatrix} = \begin{pmatrix} | & | & & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \\ | & | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \sigma_r & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix} \begin{pmatrix} - & \mathbf{v}_1^T & - \\ - & \mathbf{v}_2^T & - \\ - & \vdots & - \\ - & \mathbf{v}_n^T & - \end{pmatrix}$$



$$SV^T = \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \sigma_r & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix} \begin{pmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_n^T \end{pmatrix} = \begin{pmatrix} \sigma_1 \mathbf{v}_1^T \\ \vdots \\ \sigma_r \mathbf{v}_r^T \\ \vdots \\ \mathbf{0} \end{pmatrix}$$

$$USV^T = (\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_m) \begin{pmatrix} \sigma_1 \mathbf{v}_1^T \\ \vdots \\ \sigma_r \mathbf{v}_r^T \\ \vdots \\ \mathbf{0} \end{pmatrix} = (\mathbf{u}_1)(\sigma_1 \mathbf{v}_1^T) + \cdots + (\mathbf{u}_r)(\sigma_r \mathbf{v}_r^T)$$



$$A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T$$



# INTERPRETAÇÃO

$$A = \sigma_1 u_1 v_1^T + \cdots + \sigma_r u_r v_r^T$$

Os valores singulares são ordenados por ordem decrescente. Eles correspondem a um novo conjunto de características que são uma combinação linear dos características originais. A primeira característica explica a maior parte da variância dos dados.

# VOLTEMOS AO NOSSO EXEMPLO...

$$\mathbf{A} = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$$

A matriz  $\mathbf{A}$  é  $2 \times 3$  e possui 2 autovalores não nulos ( $r = 2$ ).

$\mathbf{U}$  tem dimensão  $2 \times 2$ ,  $\mathbf{S}$  tem dimensão  $2 \times 3$  e  $\mathbf{V}^T$  tem dimensão  $3 \times 3$ ,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix} \quad \mathbf{S} = \begin{pmatrix} 5 & 0 & 0 \\ 0 & 3 & 0 \end{pmatrix} \quad \mathbf{V}^T = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 1/\sqrt{18} & -1/\sqrt{18} & 4/\sqrt{18} \\ 2/3 & -2/3 & -1/3 \end{bmatrix}$$

$$\mathbf{A} = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T$$

$$\mathbf{U} = \begin{bmatrix} \overset{\mathbf{u}_1}{1/\sqrt{2}} & \overset{\mathbf{u}_2}{1/\sqrt{2}} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}$$

$$\mathbf{A} = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$$

$$\mathbf{S} = \begin{pmatrix} \overset{\sigma_1}{5} & 0 & 0 \\ 0 & \overset{\sigma_2}{3} & 0 \end{pmatrix}$$

$$\mathbf{V}^T = \begin{bmatrix} \overset{\mathbf{v}_1^T}{1/\sqrt{2}} & 1/\sqrt{2} & 0 \\ 1/\sqrt{18} & -1/\sqrt{18} & 4/\sqrt{18} \\ \overset{\mathbf{v}_2^T}{2/3} & -2/3 & -1/3 \end{bmatrix}$$

$$\mathbf{A} = \overset{\sigma_1}{5} \overset{\mathbf{u}_1}{\begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}} \overset{\mathbf{v}_1^T}{\begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \end{pmatrix}} + \overset{\sigma_2}{3} \overset{\mathbf{u}_2}{\begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}} \overset{\mathbf{v}_2^T}{\begin{pmatrix} 1/\sqrt{18} & -1/\sqrt{18} & 4/\sqrt{18} \end{pmatrix}}$$

# VEJA O EXEMPLO DO NOTEBOOK

$$A = \begin{bmatrix} 4 & 1 & 3 \\ 8 & 7 & -2 \\ 1 & 5 & 4 \end{bmatrix}$$


Os valores  
singulares são

$$\sigma_1 = 11,97$$

$$\sigma_2 = 5,57$$



$$\sigma_3 = 3,25$$

O rank de  $A_k$  é 3. Então  
 $Ax$  é um elipsóide no  
espaço 3-d.



AN

Se usarmos apenas os dois primeiros  
valores singulares, o rank de  $A_k$  será  
2 e  $A_k$  multiplicado por  $x$  será um  
plano.



Se aproximarmos usando o  
primeiro valor singular, o rank  
de  $A_k$  será 1 e  $A_k$  multiplicado  
por  $x$  será uma linha

68

# DIFERENÇAS ENTRE SVD E DECOMPOSIÇÃO EM AUTOVALORES

*The singular value decomposition (SVD) provides another way to factorize a matrix, into singular vectors and singular values. The SVD allows us to discover some of the same kind of information as the eigendecomposition. However, the SVD is more generally applicable.*

— Ian Goodfellow, Yoshua Bengio, Aaron Courville, *Deep Learning (Adaptive Computation and Machine Learning series)*, pags. 44-45, 2016.

- Nem todas as matrizes possuem uma decomposição em autovalores, porém toda matriz tem uma decomposição em valores singulares.

# SVD: O TEOREMA FUNDAMENTAL DA ANÁLISE DE DADOS COM MÚLTIPLAS VARIÁVEIS

A decomposição em valor singular é uma técnica fundamental para análise de dados multivariados. Por exemplo, SVD é usado para cálculo de **Pseudo inversa**.

Um objetivo comum da análise de dados multivariada é reduzir a dimensão do problema, escolhendo um pequeno subespaço que captura propriedades importantes dos dados.

Dado que os elementos diagonais da matriz (chamados de valores singulares) no SVD são calculados em ordem decrescente, usa-se SVD para uma **aproximação por matriz de baixo rank**, i.é, redução de dimensão:

- **Análise de componentes principais**



# INVERSA E DADOS REAIS

$$Ax = b$$
$$x = A^{-1}b$$

Mas nem todas as matrizes são inversíveis.

# PSEUDOINVERSA MOORE-PENROSE

Pseudo inversa de  $A$ :

$$A^+$$

de forma que

$$x \approx A^+ b$$

$$Ax = b$$

$$(U, S, V) \leftarrow \text{svd}(A)$$

$$A^+ = VS^+U^T$$

$$A = USV^T$$

$$A^{-1} = (USV^T)^{-1}$$

$$A^{-1} = (V^T)^{-1}S^{-1}U^{-1}$$

onde  $S^+$  é o recíproco  $\frac{1}{x_i}$  dos elementos não nulos de  $S$

$$\begin{bmatrix} -3 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 0 \end{bmatrix}^+ = \begin{bmatrix} -1/3 & 0 & 0 \\ 0 & -1/4 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$



# EXEMPLO

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \quad (\text{singular, inversa não existe})$$

$$A = USV^T = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

$$A^+ = VS^+U^T = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1/2 & 0 \\ 0 & 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{4} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$



# APROXIMAÇÃO POR MATRIZ DE BAIXO RANK

Eliminação de ruídos, PCA,  
compactação de arquivos, etc...




PCA


Qual a ideia?

# ANÁLISE DE COMPONENTES PRINCIPAIS

A Análise de Componentes Principais ou PCA (Principal Component Analysis) tem como objetivo **encontrar um meio de condensar a informação contida em várias variáveis originais em um conjunto menor de variáveis estatísticas (componentes) com uma perda mínima de informação.**



Uma questão-chave na análise de dados é descobrir **quais variáveis são responsáveis pela maior parte da variação nos dados** – essas podem não ser as variáveis que você mediu, mas podem ser uma combinação linear das variáveis medidas!




# EXEMPLO

$$A = \begin{bmatrix} -1,03 & 0,74 & -0,02 & 0,51 & -1,31 & 0,99 & 0,69 & -0,12 & -0,72 & 1,11 \\ -2,23 & 1,61 & -0,02 & 0,88 & -2,39 & 2,02 & 1,62 & -0,35 & -1,67 & 2,46 \end{bmatrix}$$



SVD:

$$S = \begin{bmatrix} 6,040 & 0 \\ 0 & 0,218 \end{bmatrix}$$

Com um valor singular muito maior que o outro, pode-se assumir que o pequeno valor de  $\sigma_2$  é devido ao ruído nos dados e que esse valor singular seria idealmente zero.



Nesse caso, a matriz teria uma classificação, o que significa que todos os dados estão na linha definida por  $u_1$ .



# FAÇA VOCÊ


$$A = \begin{bmatrix} 2.9 & -1.5 & 0.1 & -1.0 & 2.1 & -4.0 & -2.0 & 2.2 & 0.2 & 2.0 & 1.5 & -2.5 \\ 4.0 & -0.9 & 0.0 & -1.0 & 3.0 & -5.0 & -3.5 & 2.6 & 1.0 & 3.5 & 1.0 & -4.7 \end{bmatrix}$$






# COMPACTAÇÃO DE IMAGEM (720, 540)

Compactação da imagem feita  
utilizando SVD.

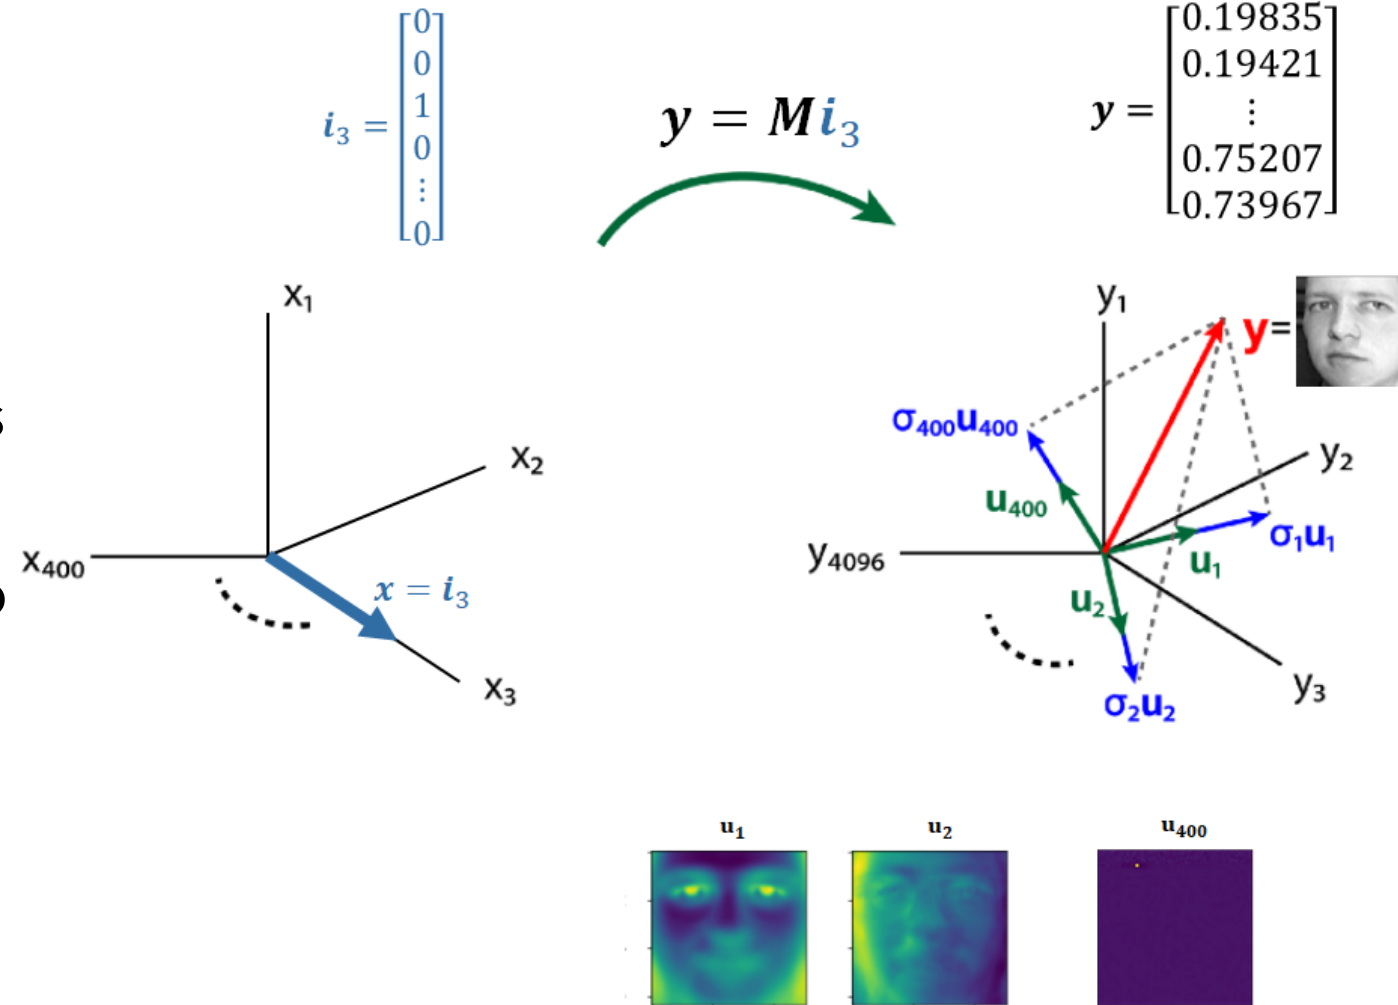
$$A = \sigma_1 u_1 v_1^T + \dots + \sigma_r u_r v_r^T$$





# EIGENFACES

O termo *Eigenfaces* refere-se, basicamente, a um conjunto de características que definem a variação global entre as imagens faciais. O objetivo é **representar uma imagem que retrata o rosto de uma pessoa como uma combinação linear de um conjunto de imagens básicas chamadas de eigenfaces.**



# MATRIZ $M$

O termo *Eigenfaces* refere-se, basicamente, a um conjunto de características que definem a variação global entre as imagens faciais. O objetivo é representar uma imagem que retrata o rosto de uma pessoa como uma combinação linear de um conjunto de imagens básicas chamadas de eigenfaces.



$$\begin{bmatrix} 0.310 & 0.368 & \dots & 0.306 \\ 0.343 & 0.405 & \dots & 0.314 \\ \vdots & \vdots & \ddots & \vdots \\ 0.157 & 0.202 & \dots & 0.207 \end{bmatrix} \rightarrow \mathbf{f}_1 =$$

$$\begin{bmatrix} 0.310 \\ 0.368 \\ \vdots \\ 0.306 \\ 0.343 \\ 0.405 \\ \vdots \\ 0.314 \\ \vdots \\ 0.202 \\ 0.207 \\ \vdots \\ 0.157 \end{bmatrix}$$



$$M = [\mathbf{f}_1 \quad \mathbf{f}_2 \quad \mathbf{f}_3 \quad \dots \quad \mathbf{f}_{400}]$$



# ENTREGA NO MOODLE ATÉ 24/03, 23:59

Antes de fazer a lição, estude a aula. Responda às questões manualmente:

1. Encontre os valores singulares das matrizes abaixo:

$$A_1 = \begin{bmatrix} 1 & 0 \\ 0 & -3 \end{bmatrix} \quad A_2 = \begin{bmatrix} -5 & 0 \\ 0 & 0 \end{bmatrix}$$

2. Construa o SVD de cada matriz abaixo:

$$A_3 = \begin{bmatrix} 2 & -1 \\ 2 & 2 \end{bmatrix} \quad A_4 = \begin{bmatrix} 7 & 1 \\ 0 & 0 \\ 5 & 5 \end{bmatrix} \quad A_5 = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{bmatrix}$$

# OPCIONAL

1. Com os dados de altura e peso de homens e mulheres, que você pode retirar do link\* ,

- Ache a matriz  $A$ ;
- Ache os valores singulares;
- Ache  $U, S, V^T$ ;
- Escreva a matriz na forma aproximada,

$$A_k = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \cdots + \sigma_k \mathbf{u}_k \mathbf{v}_k^T;$$

- Discuta suas conclusões, analisando a matriz  $A_k$ .

\*<https://www.kaggle.com/datasets/mustafaali96/weight-height>





# ATÉ A PRÓXIMA SEMANA!!!

Revejam o material disponibilizado em aula. NÃO PERCAM A PRÓXIMA AULA.